

急性心衰智能快速听诊关键技术研究

Research on Key Technologies of Intelligent Rapid Auscultation for Acute Heart Failure

专业类别： 电子信息

研究方向（领域）： 生物医学工程

作者姓名： 仇兆禹

指导教师： 余辉 副教授

企业导师： 李志刚 教授

答辩日期	2024 年 5 月 28 日		
答辩委员会	姓名	职称	工作单位
主席	李奇峰	教授	天津大学
委员	撒昱	副教授	天津大学
	赵丕城	高级工程师	天津先阳科技发展有限公司

天津大学精密仪器与光电子工程学院
二〇二四年六月

独创性声明

本人声明所呈交的学位论文是本人在导师指导下进行的研究工作和取得的
研究成果，除了文中特别加以标注和致谢之处外，论文中不包含其它人已经发表
或撰写过的研究成果，也不包含为获得 天津大学 或其它教育机构的学位或证
书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中
作了明确的说明并表示了谢意。

学位论文作者签名：仇兆禹 签字日期：2024年 5月 28日

学位论文版权使用授权书

本学位论文作者完全了解 天津大学 有关保留、使用学位论文的规定。
特授权 天津大学 可以将学位论文的全部或部分内容编入有关数据库进行检
索，并采用影印、缩印或扫描等复制手段保存、汇编以供查阅和借阅。同意学校
向国家有关部门或机构送交论文的复印件和磁盘。

（保密的学位论文在解密后适用本授权说明）

学位论文作者签名：仇兆禹

导师签名：周哲

签字日期：2024年 5月 28日

签字日期：2024年 5月 28日

摘要

心力衰竭是心血管疾病的末期阶段，是老年人急诊入院的高发因素。及时有效的救治与患者存活率正相关，所以快速、准确的诊断非常关键。生化指标和超声心动图检查检查心衰的准确率极高，但是由于耗时过长影响急性心衰的抢救。听诊同样作为检测心衰的方法有着快速、低廉的突出优点，缺点是存在主观的误诊、漏诊。因此开发基于听诊的急性心衰快速诊断技术有显著的临床价值，有希望在 120 救护车上就完成初诊，将原本 20~30 分钟的诊断时长压缩到 1 分钟，这有助于即时实施针对急性心衰的初步救治并缩短病房转诊耗时，从而大大降低患者死亡率、再住院率。

本文开发了面向急救场景的急性心衰快速听诊的信号采集方案、配套软件、诊断算法。设计了心电、心音同步采集方案，并适配了前处理方案。搜集建立了心衰听诊数据集，完成了算法模型的参数辨识；为解决固定时间窗导致的心音频谱泄露，提出了基于超短时心音记录的急性心衰诊断模型。完成了心音-心电的心衰复合听诊模型的验证，更加适用于快速导诊分流的临床需求。具体如下：

（1）设计了可同步采集心电、心音信息的可穿戴设备，并适配了频响修正算法与上位机软件。基于我国医疗器械标准 YY/T 1035-2021 与 YY 1139-2018，完成了需求分析与器件选型。选取了 AD8232 作为采集芯片，实现 V1、V4、LL 三个导联位置的心电采集；选取了艾医吉昌 ETZ-1 型作为拾取探头，实现二尖瓣听诊区的心音采集。设计了频响曲线修正算法，调整 50Hz~500Hz 频段增益为 20dB，符合 YY/T 1035-2021 相关标准；选取了 STM32F7671GT6 作为主控芯片，实现上位机通讯；基于 Qt5 框架，编写了上位机图形用户界面。

（2）为满足临床智能化诊断需求，开发了轻量级急性心衰听诊模型，开发过程包括：数据集搜集与清洗、信号预处理与特征提取、轻量级模型搭建与听诊策略设计。面对心衰听诊公开数据集的不足，与天津市第四中心医院合作建立了二尖瓣听诊数据集、多域融合听诊数据集和心音降噪数据集；二尖瓣听诊数据集包括 1620 例健康记录和 1379 例心力衰竭记录；多域融合听诊数据集包括 540 例健康记录和 389 例心力衰竭记录。基于小波变换实现心音信号降噪；实验得到最佳小波分解方案，提出了一个自适应阈值处理函数；基于梅尔频率倒谱信息提取心音时频特征。面对急性心衰智能听诊算法的空白，开发了一个 DenseHF-Net 诊断模型，使用了四个 Dense Block 块，模型总层数为 121 层，参数量为 3.82M，算法占用内存为 130.89M；基于二尖瓣单个听诊区域的平均准确率达到 93.63%；基于三个听诊区域的平均准确率达到 99.35%；DenseHF-Net 的总体表现优于两

个横向比较卷积神经网络：ResNet 和 MobileNet。

(3) 针对单个听诊区域心音精准量化分析的难题，引入了同步采集的心电信号实现心动周期分割，完成了必要性验证、周期分割算法设计、复合听诊模型设计、临床测试与讨论。定量评估了固定长度时间窗分割导致的频谱泄露、时频特征扰动。基于 MIT-BIH 心电数据集，设计了自适应心动周期分割算法，平均误差为 1.6 毫秒。引入心动周期分割信息，设计了多周期的集成诊断算法，将二尖瓣单个听诊区域的准确率提升至 94.41%。在三甲医院完成了设备测试和诊断可靠性讨论。

综上，本文完成了急性心衰智能快速听诊关键技术研究，包含：硬件、软件、数据集、算法，基本实现了急性心衰智能诊断功能，具有检测速度快、部署方便、采集与诊断一体化等优点，适用于救护车初诊、病房监护、导诊分流等临床场景，有希望为急性心衰患者赢得急救时间，从而提高存活率、降低死亡率。

关键词：急性心衰，心音听诊，轻量级深度学习模型，DenseHF-Net，梅尔频率倒谱系数，心动周期分割

ABSTRACT

Heart failure is the terminal stage of cardiovascular disease and a common cause of emergency hospitalization in the elderly. Timely and effective treatment is directly correlated with patient survival rates, highlighting the critical importance of rapid and accurate diagnosis. While biochemical markers and echocardiography exhibit high accuracy in diagnosing heart failure, their lengthy procedures can impede urgent interventions for acute heart failure. Auscultation, as a method for detecting heart failure, offers the advantages of being rapid and cost-effective but suffers from subjective misdiagnosis and missed diagnoses. Therefore, the development of a rapid diagnostic technology for acute heart failure based on auscultation holds significant clinical value. Such technology aims to complete initial diagnosis, typically taking 20 to 30 minutes, within one minute, potentially allowing for immediate implementation of preliminary treatment for acute heart failure and reducing the time spent on hospital transfers, thereby significantly decreasing mortality and readmission rates for patients.

This study developed a signal acquisition scheme, accompanying software, and diagnostic algorithms tailored for rapid auscultation of acute heart failure in emergency settings. A synchronized acquisition scheme is designed for electrocardiography (ECG) and heart sounds, along with compatible preprocessing methods. A dataset for heart failure auscultation was collected and utilized for parameter identification of the algorithm models. To address spectral leakage issues caused by fixed time windows, a diagnostic model for acute heart failure based on ultra-short-term heart sound recordings was proposed. Validation of the combined auscultation model of heart sounds and ECG for heart failure was completed, better suited for rapid triage in clinical settings. Specifically:

(1) A wearable device capable of synchronously acquiring ECG and heart sound information was designed, along with frequency response correction algorithms and upper computer software. Following Chinese medical device standards YY/T 1035-2021 and YY 1139-2018, requirements analysis and device selection were completed. AD8232 was selected for ECG acquisition at positions V1, V4, and LL; Ai Yigichang ETZ-1 was selected for heart sound acquisition in the mitral valve auscultation area. A frequency response curve correction algorithm was designed to adjust gains in the 50Hz to 500Hz frequency range by 20dB, complying with YY/T

1035-2021 standards. STM32F767IGT6 was chosen as the main control chip for upper computer communication, and a graphical user interface was developed using the Qt5 framework.

(2) To meet the demand for intelligent clinical diagnosis, a lightweight acute heart failure auscultation model was developed, including data collection, preprocessing, feature extraction, lightweight model construction, and auscultation strategy design. Collaboration with Tianjin Fourth Central Hospital addressed the scarcity of heart failure auscultation public datasets, resulting in datasets for mitral valve auscultation, multi-domain fusion auscultation, and heart sound denoising. The mitral valve auscultation dataset included 1620 healthy records and 1379 heart failure records; the multi-domain fusion auscultation dataset included 540 healthy records and 389 heart failure records. Heart sound denoising was achieved using wavelet transformation, with an adaptive threshold processing function proposed for optimal decomposition. Mel-frequency cepstral coefficients were used for heart sound time-frequency feature extraction. A DenseHF-Net diagnostic model was developed, consisting of four Dense Block blocks with a total of 121 layers, 3.82 million parameters, and 130.89MB of memory usage. The average accuracy for single auscultation areas reached 93.63%. For three auscultation areas, the average accuracy reached 99.35%, outperforming comparative convolutional neural networks ResNet and MobileNet.

(3) Addressing the challenge of precise quantitative analysis of heart sounds in single auscultation areas, synchronization of ECG signals was introduced for cardiac cycle segmentation, completing necessity verification, cycle segmentation algorithm design, composite auscultation model design, and clinical testing and discussion. Quantitative evaluation of spectral leakage and time-frequency feature disturbance caused by fixed-length time window segmentation was conducted. An adaptive cardiac cycle segmentation algorithm was designed based on the MIT-BIH ECG dataset, with an average error of 1.6 milliseconds. Introducing cardiac cycle segmentation information, a multi-cycle integrated diagnostic algorithm improved accuracy to 94.41% for the mitral valve single auscultation area. Equipment testing and diagnostic reliability discussions were conducted at a tertiary hospital.

In summary, this study achieved key technological advancements in intelligent rapid auscultation for acute heart failure, including hardware, software, datasets, and algorithms. It essentially realized intelligent diagnosis for acute heart failure, with

advantages such as fast detection, easy deployment, and integrated acquisition and diagnosis. It is applicable to clinical scenarios such as ambulance triage, ward monitoring, and triage diversion, offering hope for saving time in acute heart failure emergencies, thereby improving survival rates and reducing mortality rates.

KEY WORDS: Acute Heart Failure, Cardiac Auscultation, Lightweight Deep Learning Model, DenseHF-Net, Mel-Frequency Cepstral Coefficients, Cardiac Cycle Segmentation

目 录

摘 要	I
ABSTRACT	III
第 1 章 绪论	1
1.1 课题背景及研究意义	1
1.2 国内外研究现状	3
1.2.1 心衰快诊硬件方案	3
1.2.2 基于听诊的诊断算法	7
1.2.3 心电与心音的融合诊断	8
1.3 基于心音与心电的心衰快诊方法研究	9
1.4 论文组织结构	11
第 2 章 可穿戴设备设计	13
2.1 引言	13
2.2 硬件需求分析与设计	13
2.3 心电采集硬件选型与设计	15
2.3.1 心电采集硬件选型	15
2.3.2 硬件方案与导联选择	16
2.4 心音采集硬件选型与设计	19
2.4.1 心音采集硬件选型	19
2.4.2 硬件方案和听诊区域选择	21
2.5 前处理方案	23
2.5.1 心音频响曲线修正算法	23
2.5.2 上位机采集软件	25
2.6 本章小结	27
第 3 章 轻量级心衰听诊模型研究	29
3.1 引言	29
3.2 数据集建立	30
3.2.1 二尖瓣听诊数据集	30
3.2.2 多域融合听诊数据集	31
3.2.3 心音降噪数据集	32
3.2.4 心音公开数据集	32
3.3 心音的预处理	33

3.3.1 心音的小波降噪	33
3.3.2 心音的特征提取	36
3.4 DenseHF-Net 心衰诊断模型	38
3.4.1 DenseHF-Net 模型总体结构	38
3.4.2 Dense Block 子模块	39
3.4.3 同类网络模型比对分析	40
3.4.4 超参数设计与评价指标	41
3.4.5 实验环境与模型训练	42
3.5 二尖瓣单域听诊策略	43
3.5.1 实验数据集	43
3.5.2 实验结果分析	44
3.5.3 模型泛化能力评估	44
3.6 多域融合听诊策略	45
3.6.1 实验数据集	45
3.6.2 多模态特征融合	46
3.6.3 模型参数量对比	46
3.6.4 实验结果分析	47
3.7 本章小结	47
第 4 章 基于心动周期的心衰听诊模型研究	49
4.1 引言	49
4.2 心动周期分割的必要性	49
4.3 心动周期分割算法设计	51
4.3.1 心电数据集	52
4.3.2 心动周期提取	53
4.3.3 心动周期结果分析	55
4.4 多心动周期的心衰听诊集成学习	56
4.4.1 实验数据集	56
4.4.2 模型调用与集成算法设计	56
4.4.3 实验结果分析	57
4.5 系统测试与讨论	58
4.5.1 临床数据的频谱分析	58
4.5.2 与心衰诊断金标准的比较	60
4.6 本章小结	63
第 5 章 总结与展望	65

5.1 总结	65
5.2 展望	66
参考文献	67
附录 相关伦理审查证明	73
发表论文与参与科研情况说明	75
致谢	77

第 1 章 绪论

1.1 课题背景及研究意义

心血管疾病 (Cardiovascular disease, CVD)，包括心力衰竭 (Heart failure, HF) 和中风，已成为全球死亡和残疾的主要原因^[1-4]。大部分中低收入水平国家中，心血管疾病的年发病率正在上升^[2]。心力衰竭，简称心衰，是心血管疾病发展的末期阶段，其特征是心脏收缩和舒张功能失调。急性心衰 (Acute heart failure, AHF) 是老年群体急诊入院的主要原因^[5-6]。全球范围内，急性心衰每年造成超过 2600 万人次的急诊入院，死亡率为 20-30%^[7]。急性心衰的急救程序包括救护车响应、入院-球囊扩张时间 (Door to balloon time, D2B)^[9]、急诊和病房转移。缩短前两个流程可以显著减少患者的死亡率和发病率^[8,10]。统计分析救护时长的影响，对照组减少了 15.3 分钟的救护车响应时间和 36 分钟的入院-球囊扩张时间，对应住院时间缩短了 6.3 天，死亡率降低了 12.33%，再入院率降低了 19.69%^[10]。因此，传统的急性心衰诊断流程需要优化。缩短救护车响应与入院-球囊扩张时间，甚至在救护车响应期间完成基本疾病诊断，都可以显著提高患者的生存率和康复率。




图 1-1 心衰诊断与听诊

根据欧洲心脏病学会的心衰急救指南，如图 1-1 (a) 所示，急性心衰的诊断流程通常包括：病史和体格检查、诊断性检查、超声心动图检查、心衰分级^[11]。病史检查包括：病史问询、心衰风险因素问询。诊断性检查包括：生化指标、心电图 (ECG)、胸部 X 光成像等。传统的急性心衰诊断主要依赖临床生化试验，

缺乏真正快速的检测手段，特别是对于 20%没有慢性心力衰竭（Chronic heart failure, CHF）病史的患者。生化指标是最重要的诊断依据，包括脑尿钠肽（Brain natriuretic peptide, BNP）和氨基末端脑钠肽前体（N terminal pro B type natriuretic peptide, NT-proBNP）。目前，根据市场上十种主流的 NT-proBNP 和 BNP 生化检测设备，BNP 结果的等待时间为 9-16 分钟，NT-proBNP 结果的等待时间为 11-21 分钟^[12]。超声心动图获得的射血分数也是 AHF 术前评估的重要指标^[13]，每次检查需要 20-30 分钟，其中包括设备定位需花费五分钟。

心脏听诊是体格检查的重要组成部分，可用于评估是否存在液体潴留、心脏异常音，也可快速识别并评估急性心衰症状，如心音的强度、节律和音调的异常。通常使用心脏关键听诊区域：二尖瓣听诊区，捕获急性心衰相关的特定心音。本文旨在基于短时长的心脏听诊数据，开发急性心衰的快速诊断智能方法。通过听诊这一便捷体格检查方法，将原本 20-30 分钟的诊断时长压缩到 1 分钟，服务于急救导诊分流场景，提供辅助诊断技术支持。

在便捷性之外，心脏听诊的准确性和诊断价值也已经得到临床医生一致认可，被欧洲心脏病学会推荐为一级诊断指标^[11]。心脏声音由心脏动态机械运动产生，是心血管系统内血液流动的总和。考虑到心脏声音产生的机制，它们包含了丰富的有关心血管系统生理学的信息，并被视为对心脏收缩和伸展功能的直观描述^[14, 15]。正常的心脏声音包括 4 个部分，在心脏周期中依次称为第一心音（S1）、第二心音（S2）、第三心音（S3）和第四心音（S4）。二尖瓣区（Mitral Valve Area）、主动脉瓣区（Aortic Valve Area）和肺动脉瓣区（Pulmonary Valve Area）是三个最常用的听诊区域，如图 1-1（b）所示。与心电图不同，心脏声音是室腔泵血能力的表现，可以更好地在单个心脏周期内反映病理信息。例如，异常的心脏声音具有更多的背景噪音，更大的 S1 振幅波动以及比正常心脏声音更多的高频细节。当考虑心音的定量信息时，听诊频段是至关重要的。心音的听诊频段主要集中在 20 Hz 到 500 Hz 范围^[16-17]。在这个频段内，心音的不同部分对应着不同的生理和病理状态。例如，第一心音通常反映了心室收缩的开始，而第二心音则对应着主动脉和肺动脉瓣膜关闭。随着个体病理条件的变化，心音的特征也会发生相应的变化。例如，在心力衰竭的情况下，常常伴随着第三心音的出现，而心脏瓣膜疾病可能导致 S1 和 S2 的改变^[16]。此外，心音的强度、持续时间和频谱特征在不同的病理状态下也会有所不同，这为诊断提供了重要线索。

然而，心脏听诊也存在一些挑战和不足之处^[17-20]。一方面，听诊者的主观判断和听诊环境中的噪音干扰可能影响诊断的准确性。另一方面，一些心脏病变可能不会引起明显的心音改变，或者出现与其它病症类似的心音表现，这都增加了诊断的困难。为了克服这些障碍，需要先进的硬件方案和后续快速诊断算法的支

持。先进的听诊设备，如高灵敏度的电子听诊器和智能噪音过滤技术，可以提高诊断的准确性和可靠性。同时，基于机器学习、人工智能开发的快速诊断算法，可以帮助医生从心音数据中提取并识别关键特征，从而缩短诊断时长。与心电图的结合使用也是提高心音诊断准确性的重要途径^[20-28]。引入同步采集的心电记录，可以更准确地确定心动周期，从而得到更高的识别准确率和 F1 分数^[20]。心音分割的意义还在于能够独立分析 S1、S2 等各部分的能量分布与异常，如杂音（Murmurs）与迸射音（Ejection clicks）^[22]。

综上，现有急性心衰诊断的痛点在于：（1）生化检查与影像检查耗时长，与快诊需求矛盾突出；（2）缺乏高质量听诊记录，医师、护士的诊断主观性大，临床听诊容易漏诊、误诊；（3）听诊缺乏多模态采集设备，现有设备无法很好同步采集心电与心音。随着可穿戴设备与人工智能技术的发展，开发针对急性心衰的智能设备与算法，不仅可以采集多模态心衰患者记录，为实习医生累积大量学习资料，而且对急性心衰的快速诊断有重大临床价值。

本文面向 120 急救与入院后快速导诊分流决策场景，对标急性心衰诊断的便捷化、客观化、自动化需求，完成了一系列关键技术研发与验证，涉及硬件设备、软件、数据集、算法。为实现多部位临床采集需求，设计了心电、心音一体化可穿戴采集设备；完成了符合医疗器械行业标准的频响修正；开发了图形化采集界面。为解决心衰听诊样本不足问题，与天津市第四中心医院合作，建立心衰听诊数据集，为智能诊断算法提供数据和标签支撑；结合公开数据集，设计了降噪算法与特征提取算法；提出了 DenseHF-Net 心衰诊断模型；基于 DenseHF-Net 模型，提出了两种不同的听诊策略应对 120 救护车、监护病房两种不同场景的诊断需求。为了解决单周期单部位心音快诊过程中固定长度时间窗造成的数据截断效应及频谱泄露问题，引入了心电信号实现单心动周期心音采样分析；基于 DenseHF-Net 模型和可穿戴采集设备，使用可穿戴设备采集的心电信号实现了单周期心音精准提取；基于多周期的集成诊断算法，得到最终的诊断结果。本文的研究已经在天津市第四中心医院心内科完成了采集测试，目前正在进行二类医疗器械注册申请。

1.2 国内外研究现状

1.2.1 心衰快诊硬件方案

动态心电图仪（Holter）是最常见的可穿戴心脏监护设备^[29-35]，通常持续 24 小时或更长时间，使用方法如图 1-2 所示。Holter 监测的主要目的是检测心律失

常和评估心脏功能，特别是在患者经历症状（如胸痛、心悸或晕厥）时。Holter 由多个导联组成，这些导联贴在患者的胸部，记录了心脏电活动的变化。通过长时间的监测，医生可以更好地了解患者的心脏电活动，并诊断可能存在的问题^[36]。Holter 的心电图参数可以用于预测死亡率与心衰程度^[37]，包括：心率变异性（Heart rate variability）、心率涡流（Heart rate turbulence）、复极化动力学（Repolarization dynamics）和变异性（Variability）。心率变异性与心衰发病率强相关^[38]。慢性心衰患者较之健康人群有更低的心率变异性^[39]。II 级心衰患者（美国纽约心脏病学会分级标准）具有较高的窦性心搏间标准差（Standard deviation of all normal N-N intervals, SDNN）和平均正常 NN 间期的标准差（Standard deviation of the average NN intervals, SDANN）^[39]。持续性、非持续性的室性心动过速患者都有具有较低的 SDNN 和 SDANN 值^[39]。


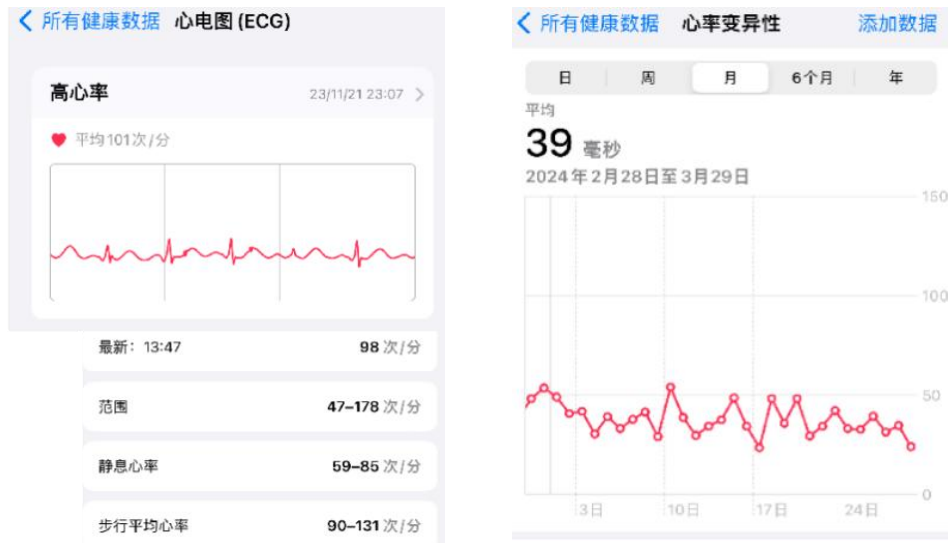


图 1-2 Holter 使用示例^[40]

近些年出现了一些具有心脏监护功能的消费电子产品，如 Apple Watch。基于内置光学心率传感器和加速度计，Apple Watch 实现了心率监测功能。基于指尖电信号采集，Apple Watch 实现了心电检测功能^[40-43]。采集实例如图 1-3 所示，Apple Watch 的心脏监护功能包括：心率监测、心电图和心脏健康提示等。心脏健康提示包括：低心率提示、高心率提示、心率不齐提示、房颤提示和心率变异性提示。Apple Watch 的移动心电图房颤软件已获美国食品药品监督管理局（Food and Drug Administration, FDA）认证。国内获得中国食品药品监督管理局医疗器械注册证的产品包括：乐心智能手表 Health Watch H1、OPPO Watch ECG 版

和华为 Watch GT2 Pro ECG。基于可穿戴消费电子产品的心衰监护同样有潜力。LINK-HF 使用了一种多参数贴片传感器，具备心电图监测、胸腔内阻抗检测、加速度检测和温度检测功能^[44]。LINK-HF 对 100 名心力衰竭患者进行监测，基于机器学习的心衰失代偿警报的灵敏度为 76%，特异性为 85%^[44]。ReDS (Remote dielectric sensing) 是一种用于治疗心力衰竭的背心。在 50 名患者的观察性研究中，穿戴设备 90 天后住院可能性降低了 87%，卸除穿戴设备的 90 天后住院可能性增加了 79%^[45]。



(a) 心电图

(b) 心率变异性



(c) Apple Watch 采集实例

图 1-3 Apple Watch 使用实例

电子听诊器的金标准是 3M 公司生产的 Littmann 3200 型听诊器。Littmann 3200 结合了传统的听诊器设计和现代的数字技术，提供了许多高级功能，使医

生能够更准确地评估患者的心脏和肺部状况^[47-52]。电子听诊器在心衰患者的诊断和监护中发挥着重要作用。首先，电子听诊器能够捕捉和记录心脏和肺的音频信号，包括心音、杂音和呼吸音等。这些信号可以提供医生详细的心血管和呼吸系统信息，有助于心衰诊断和严重程度判断。其次，电子听诊器通常配备了先进的信号处理技术，从而实现信号放大、过滤和特征分析。通过这些技术，医生可以更准确地识别心脏和肺部病变的迹象。Littmann 3200 电子听诊器具有采集与记录整理功能，如图 1-4 所示。电子听诊器还可以与其它医疗设备或电子医疗记录系统进行连接，实现数据的共享和追踪。EKO CORE 500 电子听诊器是另外一款常用电子听诊器，具有与 Littmann 3200 类似的数字放大、数字滤波、录音、蓝牙通讯功能，还具有心电图和人工智能辅助诊断功能，可以能够自动分析听诊音，并提供初步的诊断建议，帮助医生更快速地发现潜在的心脏和肺部疾病^[53-56]。EKO CORE 500 电子听诊器可以 15 秒内完成疾病诊断，诊断疾病包括：心力衰竭、房颤、瓣膜功能不全。2019 年，基于 EKO CORE 500 电子听诊器、物联网系统、云存储技术，在台湾成功大学医院实现远程心脏疾病诊断^[53]。2020 年，基于 EKO CORE 500 电子听诊器，完成了与专家诊断和超声心动图诊断的替代性验证。完成了 54 人的 270 人次的采集，与现场专家听诊结果相比 EKO CORE 500 电子听诊器的一致性为 88-96%，与超声心动图诊断相比 EKO CORE 500 电子听诊器的一致性为 88-94%^[54]。

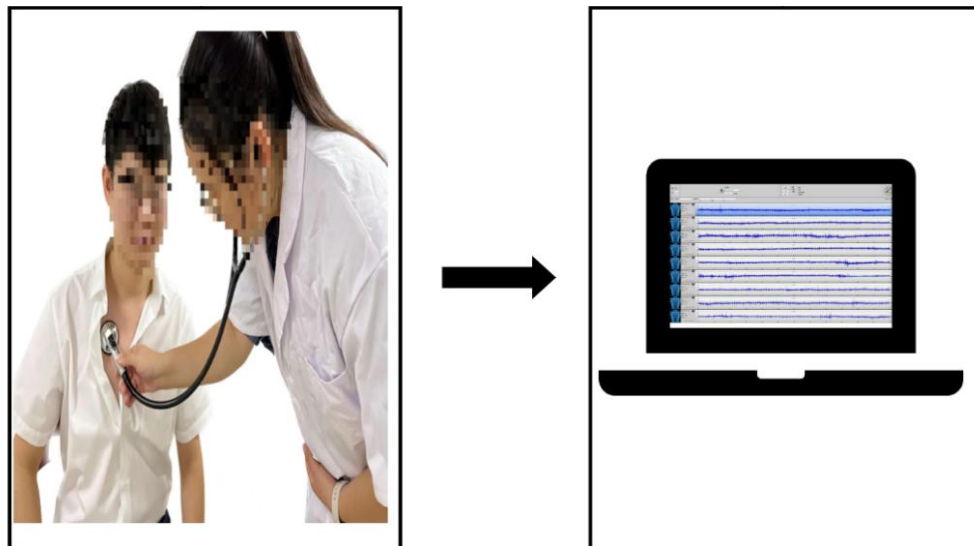


图 1-4 Littmann 心音采集与保存实例

国内也有很多心脏诊断相关成果^[57-60]。

2022 年，李凤^[57]开发了针对正常、异常心音二分类的诊断设备，设备组成

包括：音频拾取传感器、放大电路、滤波电路和微控制芯片。音频拾取传感器使用了 HKY06B 型压电传感器，放大电路增益设置为 5，滤波电路包含低通滤波电路与工频陷波电路，信号的采集与通讯使用了 STM32F103C8T6 作为主控芯片。

2022 年，苗家良^[57]开发了可穿戴一体式心电采集手套，设备组成包括：采集导联、采集电路、微处理模块、存储模块和传输模块。心电采集模块使用了 ADS1298 作为采集芯片，微处理模块使用了 STM32F4x3VxT6 作为主控芯片，输出模块使用了 SDIO 接口与 SD 卡，传输模块使用了 EC20 作为 4G 传输芯片。

2023 年，向梦辉和王朔彤^[58-60]开发了针对正常、异常心音二分类的诊断设备，设备组成包括：听诊探头、高灵敏采集单元、信号采集电路、滤波放大电路和微控制芯片，采用 LP2985AIM5 作为电源控制芯片，采用高精度 MEMS 心音传感器作为音频拾取传感器。信号处理电路包含二阶低通滤波器与二阶高通滤波器。音频输出采用 MAX4410 作为模拟信号输出芯片。采用 STM32F103RCT6 作为主控芯片，实现信号采集与上位机通信。

综上所述，目前已经存在大量的心脏监护硬件的技术研究与商业产品。但缺乏面向急救场景快诊需求的设备，也缺乏心音-心电双模态采集硬件方案。因此本文计划开发针对急性心衰诊断的可穿戴手套设备，同步采集心电信息与心音信息，对应急性心衰诊断的便捷化、多模态化临床需求。

1.2.2 基于听诊的诊断算法

当前数字心音听诊技术研究内容涵盖数据集、信号处理和诊断模型等方面。

在数据集方面，最常用的数据集是 2016 年 PhysioNet 心音分类挑战赛的公开数据集^[61]。该数据集包括了 665 个异常心音和 2575 个正常心音。心音样本通过数字录音设备采集，并经过专业医生的标注。每个心音样本都附带有相应的标签，标签分为正常心音和异常心音，部分标注了异常心音的具体类型。数据集的创建目的是促进心音分类算法的研究和发展，用以训练机器学习、深度学习模型，识别和分类心脏疾病相关的心音。另外一个常用公开数据集由 Yaseen 等人^[62]提供，包含主动脉瓣狭窄（Aortic Stenosis, AS）、二尖瓣返流（Mitral Regurgitation, MR）、二尖瓣狭窄（Mitral Stenosis, MS）、二尖瓣脱垂（Mitral Valve Prolapse, MVP）和正常（Normal, N）五类的数据集，每类 200 个案例。目前现有的公开数据难以用于特定心脏疾病的诊断算法开发，如心衰。因此，为了开发用于急性心力衰竭的快速诊断模型，需要建立具有健康、心衰两种病理标签的高质量听诊数据集。

在心音的预处理和特征提取方面，已有许多数字化处理技术，为进一步的分析和诊断打下基础。在 Vepa 等人^[63]的研究中，心音信号经历了短时傅里叶变换（Short-Time Fourier Transform, STFT）和离散小波变换（Discrete Wavelet

Transform, DWT)。这些变换技术可以将时域心音信号转换到频域信号,更易于提取和分析。在 Wu 等人^[64]的研究中,使用了隐马尔可夫模型 (Hidden Markov Model, HMM) 和梅尔频率倒谱系数 (Mel-Frequency Cepstral Coefficients, MFCC)。MFCC 是一种常用的语音特征提取方法,适用于心音信号分析。基于 MFCC 的广泛应用于心音的特征提取。然而,当前的心音处理技术主要使用长信号,有些甚至超过 60 秒,不适用于急性心力衰竭的快速诊断。因此,针对急性心衰的快速诊断,需要进一步研究和开发新的技术和方法,以处理短时心音信号并提取有效的特征。

在诊断模型方面,最早在 Rubin 等人^[65]的研究中,使用了卷积神经网络 (Convolutional Neural Networks, CNN) 对心音信号的时频特性进行分类识别。在 Arora 等人^[66]的研究中,使用了基于 VIZ、MobileNet、Xception、VGG、ResNet、DenseNet 和 Inception 对心音信号进行迁移学习。在 Li 和 Shuvo 等人^[67-68]的研究中,开发了移动端使用的端到端轻量级神经网络。

综上所述,现有数据集缺乏高质量心衰听诊开源数据集。现有模型参数量过多,不适用于急性心衰的快速诊断,包括:计算资源需求增加:大模型需要更多的计算资源,导致临床现场资源成本上升;实时性受限:大模型可能需要更长的时间来完成诊断过程,与急性心衰快速诊断需求相悖。因此,本文建立了高质量心衰听诊数据集,包含二尖瓣、主动脉瓣、肺动脉瓣三个听诊区。开发了轻量级诊断模型,并针对不同的临床场景设计不同的听诊策略。

1.2.3 心电与心音的融合诊断

心音数字化分析结合同步心电数据十分必要。在 Lee 等人^[20]的研究中,讨论了引入心电辅助心音周期划分的必要性。心电辅助心音分类对正常心音信号的分类准确率达到 100%,对有心脏杂音的心音信号分类准确率达到 96.7%。过往研究只能获取心音信号,无法从心音信号中区分 S1 和 S2 的位置。Lee 等人^[20]的研究可视化心音和心电图信号,从而方便诊断。在 Fernando 等人的研究中^[22],讨论了不同能量计算组合的心动周期切割效果,包括包络、小波、MFCC 特征等。M3-Hu 数据集上自动分段心音结果与标签一致。研究使用了 17k 个模型参数,运行于 2.5G Hz 主频的核显中,在 56.88 秒内完成了 1000 个心动周期切割。

现有研究广泛通过检测 R 峰位置得到心动周期坐标位置^[23-25]。在 Niroshana 等人^[23]的研究中,使用自适应加窗算法检测心动周期边界,在 MIT-BIH 数据集^[26]上获得 99.25%的检测准确率。在 Peng 等人^[24]的研究中,使用改进 U-net 模型检测 QRS 复合波和 R 峰位置,在 MIT-BIH 数据集上获得 99.76%的检测灵敏度。

综上所述,基于心电的心动周期分割研究使用了 R 峰检测坐标,从而实现

了高精度的快速分割。因此本文的研究需要开发自适应 R 峰检测算法，从而使自动化急性心衰诊断速度快、准确率高。

1.3 基于心音与心电的心衰快诊方法研究

结合临床现状，目前开发一种基于心音的急性心衰自动化诊断方法的难点在于：（1）缺少可二次开发的高质量硬件方案；（2）开发信号处理算法与心衰诊断算法缺乏高质量数据集；（3）使用心音这一单一体格检查手段可解释性不足。结合国内外研究现状，现有的硬件方案大都是不开源的商业产品。目前也缺少带标签的高质量心衰患者与健康被试者听诊记录。心音的数字化分析工作相对丰富，但大多仅使用了心音，缺乏多模态金标准的联合诊断。心电-心音双模态的联合诊断有更好的可解释性，也更符合临床诊断流程。

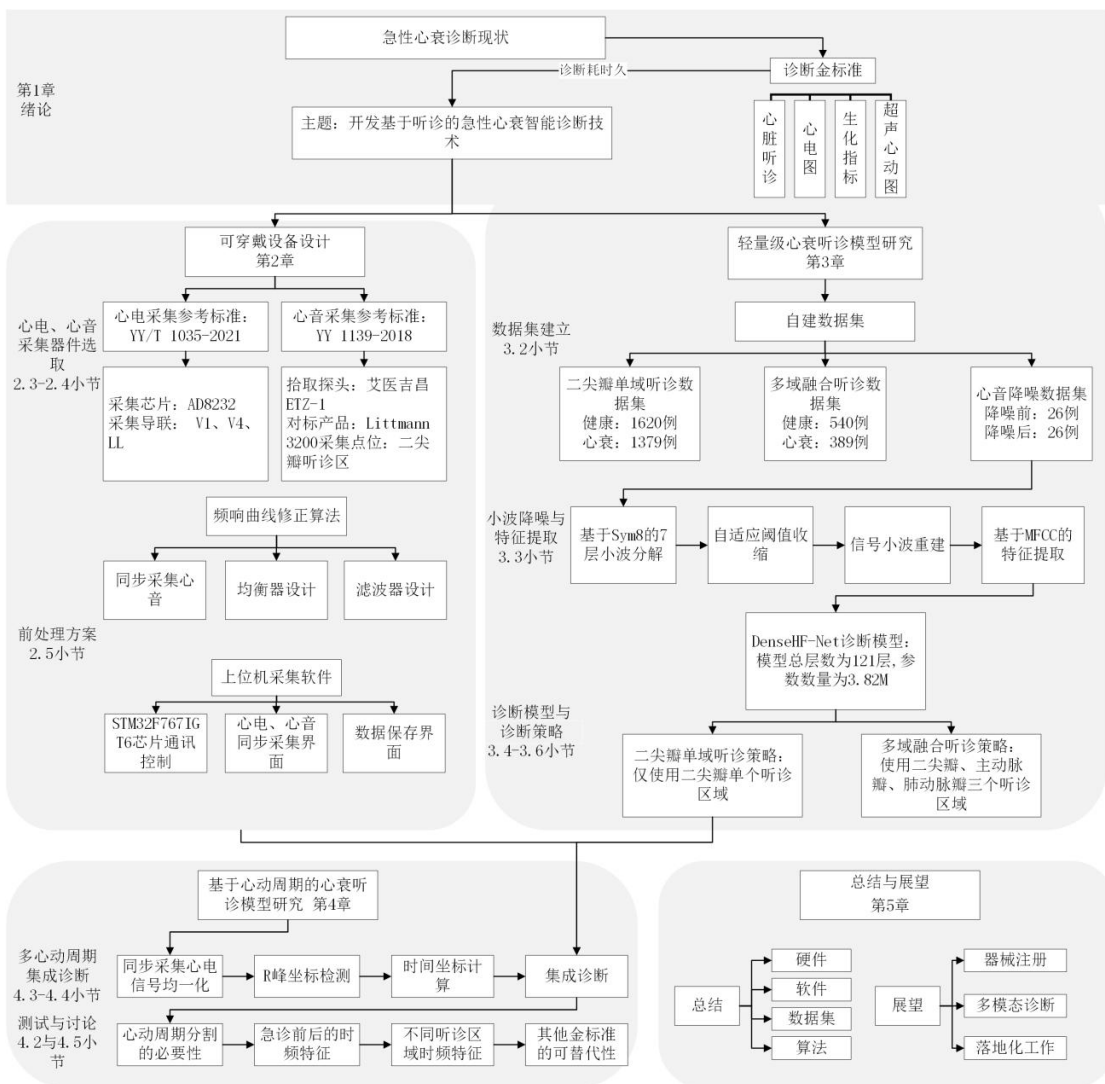


图 1-5 研究内容与工作路线

本文设计了心电、心音同步采集的可穿戴设备；与三甲医院临床医生沟通，选取手套作为采集设备原型；参考了心电采集手套的设计原理，加入了心音采集功能；心音采集使用了二尖瓣听诊区这一急性心衰最重要的听诊区；心电采集使用了 V1、V4、LL 三个采集区域，与 AD8232 心电监护芯片配合使用。鉴于公开数据集数量不足以及缺乏心衰相关病历标签，因此与天津市第四中心医院合作采集临床心衰听诊数据集；3.2.1 章的心衰听诊数据集与 3.2.2 章的心音降噪数据集是两个自建数据集；所有志愿者都已签署知情同意书，研究计划与方案已通过天津市第四中心医院医学伦理委员会的批准（批准号：No. 2022-T050）。鉴于心音单一诊断手段的限制，使用了自研可穿戴设备的心电采集功能，引入心电信号得到心动周期起止点时间标签，为最终诊断结果提供支持。

本文的主要工作技术路线如图 1-5 所示。本文的第二章“可穿戴设备设计”是硬件设计与选型过程。本文的第三章“轻量级心衰听诊模型研究”是诊断算法的开发过程。本文的第四章“基于心动周期的心衰听诊模型研究”是算法与硬件结合的研究过程。

硬件方面的工作包括：心音采集、心电采集、心音心电一体化采集设备。心音采集参考国标 YY/T 1035-2021《听诊器》，重点考虑拾音范围、增益指标。心电采集 YY 1139-2018《单道和多道心电图机》，重点考虑灵敏度、共模抑制比、温漂、基漂指标。

软件方面的工作包括：心音心电同步采集软件、被试者信息录入软件。软件设计参考 Littmann 3200 配套软件的界面设计。

数据集方面的工作包括：二尖瓣单域听诊数据集、多域融合听诊数据集、心音降噪数据集。数据集搜集历时两年，辗转六类病房，一共采集 71.6 分钟的心力衰竭患者听诊记录和 81 分钟健康人听诊记录，标签包含性别、年龄、入院原因、超声心动指标、生化指标等。心音降噪数据集包含 26 种异常病理心音，经由两位主任医师认可。

算法方面的工作包括：心音频响曲线修正算法、心音降噪算法、特征提取算法、诊断模型算法、心动周期分割算法、多周期集成诊断模型算法。心音频响曲线修正算法参考自 Littmann 3200 的心音听诊工作模式，更加关注 50Hz~500Hz 频段。并且满足 YY/T 1035-2021《听诊器》要求 500Hz 以内频段的增益衰减在 30dB 以内。

本文的主要创新点如下：

(1) 针对急性心衰的快速诊断的需求，提出了一体式可穿戴手套设备。实现同步采集心音与心电信号，并开发了与硬件配套算法与软件。

(2) 面对心衰听诊公开数据集的缺失, 与天津市第四中心医院合作建立了三个心音数据集。听诊区包含: 二尖瓣、肺动脉瓣、主动脉瓣。采集心衰、健康两类人群, 录入典型信息标签。

(3) 面对急性心衰诊断在数字化听诊领域的空白, 开发了一个 DenseHF-Net 智能诊断模型。基于 DenseHF-Net, 二尖瓣单域听诊策略下的平均准确率为 93.63%, 多域融合听诊策略下的平均准确率为 99.35%。

(4) 针对短时长心音分析中固定长度时间窗分割导致的频谱泄露、时频特征扰动问题, 引入了心电精准提取单周期心音, 进而基于多个心动周期诊断结果集成诊断, 平均准确率提升至 94.41%。

1.4 论文组织结构

第一章介绍了课题背景与意义。介绍了急性心衰听诊诊断的现状、听诊作为快速检测手段的潜力。就听诊硬件设备、心音数字化处理算法介绍了国内外研究方案与成果。最后简要了本文的主要工作、创新点、论文段落安排。

第二章介绍了一体化听诊手套硬件设计。提出了设计需求、硬件选型指标、设备总体设计与使用方案。介绍了心音采集硬件的选型。介绍了心音采集区域的选择。介绍了心电采集硬件的选型与采集点的选择。最后介绍了与硬件相配套的频响曲线修正算法、上位机数据传输模式与采集软件设计。

第三章介绍了心衰听诊模型开发过程。研究过程包括: 数据集的建立, 包括两个自建数据集和一个公开数据集; 心音的小波降噪, 计算出了最佳的小波基与分解层数, 提出了一个自适应阈值函数; 心音的时频特征提取, 提取梅尔频率倒数系数特征; DenseHF-Net 诊断模型的搭建, 并援引了经典卷积网络用以评估性能; 提出二尖瓣单域听诊策略, 使用二尖瓣单个听诊区域, 在 3 秒内做出心衰诊断, 适用于救护车等快速诊断场景; 提出多域融合听诊策略, 使用二尖瓣、主动脉瓣、肺动脉瓣三个听诊区各 3 秒的听诊记录做出心衰诊断, 适用于病房诊断或者监护场景。

第四章提出了结合心动周期信息的心衰诊断模型, 结合了第二章的硬件与第三章的诊断算法。采集 15 秒~60 秒的二尖瓣单域长时间听诊, 适用于信息采集与医师复听。研究过程包括: 基于心电计算 R 峰时间坐标; 使用 R 峰坐标分割整周期心音; 基于多段周期的心音调用 DenseHF-Net 得到诊断结果; 基于多段诊断结果进行集成分析得到最终诊断结果。最后分析了临床数据在频谱上的特点, 并讨论了本文的必要性与有效性。

第五章对本文的全部内容进行总结。总结了现有硬件、软件、数据集、算法

的结果，并分析了仍然存在的不足之处。最后，在硬件注册、多模态诊断、模型落地三方面展望了未来研究方向。

第 2 章 可穿戴设备设计

2.1 引言

基于心衰快速诊断的临床需求，参考行业标准 YY/T 1035-2021《听诊器》与 YY 1139-2018《单道和多道心电图机》，本章设计了包含心音与心电采集的一体式可穿戴设备。与临床医师探讨后，选择手套作为可穿戴设备原型。选取了艾医吉昌 ETZ-1 型作为电子听头；选取了 AD8232 作为心电采集芯片，并设计了外围电路。按照模块化设计思想，本章详细介绍四部分工作：

首先，分析心衰快诊手套的构成，明确核心采集器件的选型指标与设计需求，对心音与心电的采集与处理进行模块化设计。

其次，对心电采集硬件进行选型，设计了心电采集外围电路与采集方式。

然后，对心音采集硬件进行选型，设计了心音采集位置与标准流程。

最后，设计了与心衰快诊手套相适配的心音频响曲线修正算法与上位机采集软件。

2.2 硬件需求分析与设计

本章的设计目标是开发一体化可穿戴手套中，实现将心音、心电信号的同步采集。在硬件设计上，需要准确定义核心指标，并提供整体设备的配套方案和使用说明。

心音采集硬件指标严格参考行业推荐标准 YY/T 1035-2021《听诊器》^[16-17]。该标准详细规定了衰减式听诊器和电子听诊器的要求。本章确保拾取范围、信号增益以及噪声水平等关键指标满足标准要求。

心电采集硬件指标部分参考行业推荐标准 YY 1139-2018《单道和多道心电图机》^[31-34]。标准适用于医院心电图设备，但并不包括心率计、心脏监护设备或心电向量图机。本文在设计中着重考虑了能耗、精度、基线稳定性和温度漂移等关键指标。

如表 2-1 所示，详细列出了本文需求调研后确认的心音采集和心电采集的核心指标要求以及相应的器件分析，并根据响应指标完成核心器件选型。综合考虑性价比及元器件采购渠道等因素后，本文选择了艾医吉昌 ETZ-1 型电子听头作为心音采集设备的前端器件，并采用 Littmann 3200 型电子听诊器进行数据采集

和算法验证。这些选择符合指标要求，将在第 2.3 章对其进行详细讨论。

在心电采集部分，本文采用了基于 AD8232 芯片^[46]的心电采集方案，确认该技术方案可以满足 YY 1139-2018 的指标要求。心电采集部分在第 2.4 章中进行详细说明。

表 2-1 核心指标要求和器件分析

心音核心指标	指标要求	心电核心指标	指标要求
拾音范围	100Hz~1000Hz	直流供电工作时间	大于 0.5h
100Hz~500Hz 频响	听头外径 35mm 以内 衰减小于 30dB	外接输出灵敏度	1V/mV 误差±5%或 0.5V/mV 误差±5%
500Hz~1000Hz 频响	听头外径 35mm 以内 衰减小于 25dB	各导联共模抑制比	大于 60dB
最大增益	小于 132dB	50Hz 干扰抑制	大于 20dB
等效输入噪声	小于 32dB	基线稳定性	小于 1mm
最大总谐波失真	小于 3%	温漂稳定性	不超过 0.5mm 每摄氏 度


本文的一体式可穿戴手套集成了心音采集与心电采集，如图 2-1(a)所示。

心音采集硬件使用了艾医吉昌 ETZ-1 型电子听头，在手套上位于中指正下方。如 2-1(b)所示，对应二尖瓣听诊区。

心电采集硬件使用了基于 AD8232 设计的电路，具有三路输入。如 2-1(b)所示，心电采集点在手套上的位置分别是：

- (1) 对应 V1 采集点的拇指指头；
- (2) 对应 V4 采集点的小指指腹；
- (3) 对应 LL 采集点的小天心穴。

最后，设备的采集示意图如 2-1(c)所示。



(c) 实际采集示意图

图 2-1 硬件采集设计示意图

2.3 心电采集硬件选型与设计

2.3.1 心电采集硬件选型

本文选用了 AD8232 作为心电采集的主控芯片。

AD8232 是一款由 Analog Devices 公司生产的生物电信号放大器集成电路 (Integrated Circuit, IC) [46]。AD8232 内置了一个仪表放大器、一个运算放大器、一个右腿驱动放大器和一个中间电源电压基准电压缓冲器。芯片专门设计用于生物医学应用,适用于对心脏生物电信号进行信号调理来进行心率监护,适用场景

包括：健身及运动心率监护仪、便携式 ECG、远程健康监护、游戏外围设备、生物电信息采集。

YY 1139-2018《单道和多道心电图机》制定了医院条件下使用的心电图机标准，并不适用于心率计、心脏监视装备、心电向量图机。本文部分参考了 YY 1139-2018《单道和多道心电图机》中关于单通道心电图机供电、输出灵敏度、稳定性等标准。如表 2-2 所示，是 AD8232 对 YY 1139-2018《单道和多道心电图机》中核心指标的满足情况。

表 2-2 心电指标要求与选型

心电核心指标	指标要求	AD8232 指标
直流供电工作时间	大于 0.5h	直流 2V~3.5V 供电，电流 0.17mA
外接输出灵敏度	1V/mV 误差 $\pm 5\%$ 或 0.5V/mV 误差 $\pm 5\%$	3V 供电条件下，小于 3.5%
各导联共模抑制比	大于 60dB	仪放共模抑制比 86dB，运放共模抑制比 100dB
50Hz 干扰抑制	大于 20dB	单电池供电
基线稳定性	小于 1mm	$\pm 0.1V$
温漂稳定性	不超过 0.5mm/ $^{\circ}C$	0.01mV/ $^{\circ}C$

标准要求直流供电情况下能够至少支持 0.5h 的工作时间。AD8232 满足超低功耗下的使用场景，最低 2V 供电情况下电流标准值为 0.17mA。标准要求外接输出情况下，1V/mV 误差在 $\pm 5\%$ 以内或 0.5V/mV 误差在 $\pm 5\%$ 以内。AD8232 的仪表放大器在 3V 供电条件下，误差典型值为 1%，误差最大值为 3.5%。标准要求各导联共模抑制比在 60dB 以上，AD8232 在 2.5V 供电条件下，仪表放大器共模抑制比典型值为 86dB，运算放大器共模抑制比典型值为 100dB。AD8232 基本使用直流供电，不考虑 50Hz 工频干扰。标准中关于设备基线稳定性与温度稳定性都是关于心电图纸的规定。AD8232 在 $-40^{\circ}C$ 到 $85^{\circ}C$ 的工作范围内，电压输出摆幅在 $\pm 0.1V$ 以内，温漂范围在 0.01mV/ $^{\circ}C$ 以内。

2.3.2 硬件方案与导联选择

AD8232 芯片采用 4mm \times 4mm、20 引脚 LFCSP 封装，内置一个专用仪表放大器、一个运算放大器、一个右腿驱动放大器和一个中间电源电压基准电压缓冲器。考虑临床上急性心衰听诊的便携与快速两大需求，本文考虑电路的低功耗、快速部署、易维护性，参考 AD8232 手册中心脏监护仪典型电路。采集场景相对

静止, 不考虑运动伪影问题。

考虑心音与心电一体化采集需求,本文的心电采集部分在采集位置上选取了传统 12 导联中的 V1、V4、LL 三个位置。电路图如图 2-2 所示。配置于心脏附近的测量,心脏信号很强并且肌肉伪像干扰较小,不易受到共模干扰影响。此处假定测量期间患者相对静止不动,不考虑运动伪像问题。为了获得失真最小的 ECG 波形,AD8232 配置为使用一个 0.5Hz 双极点高通滤波器,后接一个双极点 40Hz 低通滤波器。为实现最佳共模抑制性能,需要驱动第三个电极。运算放大器级的增益配置为 11,因此系统总增益为 1100。

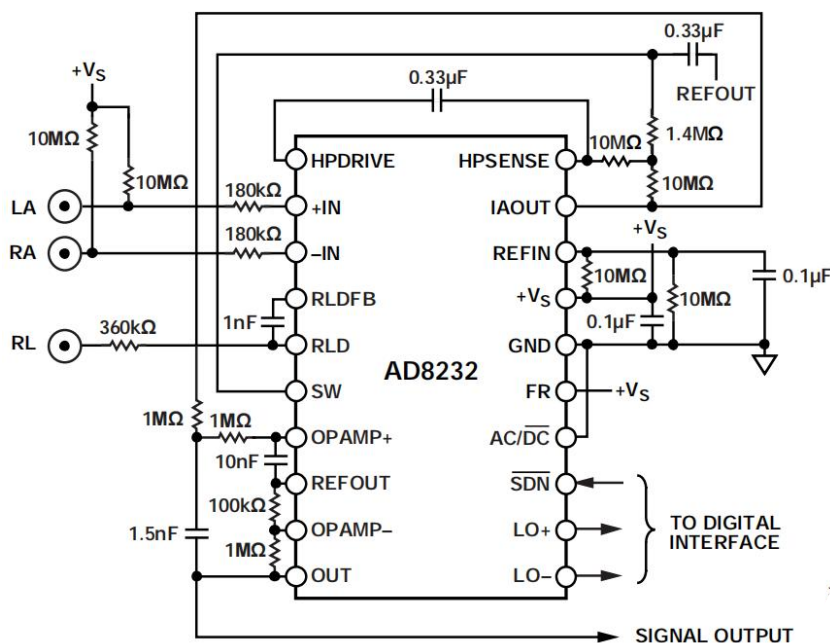


图 2-2 AD8232 采集电路图

12 导联心电图被认为是心衰在内的心血管疾病监测的^[69]。传统心电采集使用的 12 导联包含肢体导联 I、II、III、aVR、aVL、aVF 与胸导联 V1、V2、V3、V4、V5、V6^[69-71]。对应位置如表 2-3 所示，本文使用了 V1、V4、II 的 LL 导联。

导联之间的异同点主要在于其电极的放置位置不同，因此记录到的心脏电信号也有所不同。通过比较不同导联记录到的波形，可以更全面地评估心脏的电活动，发现可能存在的异常。波形区别如图 2-3 所示。

其中 I、II、III 导联是肢体导联。

I 导联主要记录心脏电活动的水平方向，用于检测心室的侧壁和前壁异常。

II 导联主要记录心脏电活动的垂直方向，用于检测心室的前壁和下壁异常。

III 导联同样记录心脏电活动的水平方向，用于检测心室的下壁和侧壁异常。

aVR 导联提供了心脏电活动的反向视角，用于检测右心室异常。

aVL 导联同样提供了心脏电活动的反向视角，用于检测左心室异常。

aVF 导联提供了心脏电活动的反向视角，用于检测心室的下壁异常。

V1、V2、V3、V4、V5、V6 是胸导联。

V1 导联主要用于观察心脏电活动在右心室区域的表现，有助于检测右心室的异常。


V2 导联用于观察心脏电活动在室间隔区域的表现，有助于检测室间隔的异常。

V3、V4、V5、V6 导联主要用于观察心脏电活动在左心室前壁的表现，有助于检测左心室的异常

表 2-3 心电采集 12 导联配置描述

导联名称	描述
I	左手腕 (LA) - 右手腕 (RA)
II	左踝部 (LL) - 右腕 (RA)
III	左踝部 (LL) - 左手腕 (LA)
aVR	右腕 (RA) - (左手腕 (LA) + 左踝部 (LL)) / 2
aVL	左手腕 (LA) - (右腕 (RA) + 左踝部 (LL)) / 2
aVF	左踝部 (LL) - (右腕 (RA) + 左手腕 (LA)) / 2
V1	第四肋间，胸骨右缘
V2	第四肋间，胸骨左缘
V3	中间位置，V2 和 V4 之间
V4	第五肋间，左锁骨中线
V5	水平于 V4，左腋中线
V6	水平于 V4 和 V5 之间，左腋中线

本文在选取导联位置时考虑到一体化检测的便利化需求。只有 50% 护士和不到 20% 心脏病专家正确放置标准 12 导联心电图的 V1 和 V2 导联^[69]，这一结果令人非常担忧。本文在心电采集部分考虑的使用的三个采集电位分别是 V1、V4、LL，与 AD8232 采集芯片相配合。

图 2-3 12 导联对应心电图波形^[70]

2.4 心音采集硬件选型与设计

2.4.1 心音采集硬件选型

心音采集是指通过各种技术手段记录和获取人体心脏活动时产生的声音。心音是由心脏的收缩和舒张过程中血液流动引起的声音，通常分为两个部分：

- （1）心脏收缩时产生的第一心音（S1），主要是由心脏的心室收缩引起的；
- （2）心脏舒张时产生的第二心音（S2），主要是由心脏的二尖瓣和主动脉瓣关闭引起的。

心音的采集由听诊器完成。YY/T 1035-2021《听诊器》中将听诊器（Stethoscope）定义为“用于测听人体心、肺等器官活动声响变化的器械”。电子听诊器是用电子器件实现其功能的听诊器，具有电子放大功能的是声增益式听诊器（Acoustic Gain Stethoscope），不具备电子放大功能的是声衰减式听诊器（Acoustic Stethoscope）。

最终选用了两款有电子放大功能的声增益式听诊器：艾医吉昌 ETZ-1 型电子听诊器、Littmann 3200 型电子听诊器。如表 2-4 所示，是两款设备对应国标核

心指标的参数。

表 2-4 心音指标要求与选型

心音核心指标	指标要求	艾医吉昌 ETZ-1 指标	Littmann 3200 指标
拾音范围	100Hz~1000Hz	50Hz~20000Hz	20Hz~1000Hz
100Hz~500Hz 频响	听头外径 35mm 以内 衰减小于 30dB	-52dB	封装 EQ 算法（经 FDA 批准，符合 HIPAA 要求）
500Hz~1000Hz 频响	听头外径 35mm 以内 衰减小于 25dB		
最大增益	小于 132dB	4 倍放大倍数	24 倍放大倍数
等效输入噪声	小于 32dB	白噪声水平小于	封装主动降噪算法
最大总谐波失真	小于 3%	-45dB	

本文采用的心音采集硬件是艾医吉昌 ETZ-1 型电子听诊器，淄博艾吉电气有限公司生产，如图 2-4(a)。设备包含一个锌合金镀镍听头，一个包含拾音电路的拾音管，一段长 TPE 纯铜导线，一个镀金 3.5mm 输出插头。以 22k 采样率输出音频模拟信号。

作为心音采集领域金标准的 Littmann 3200 型电子听诊器是一种具有 24 倍放大功能的声增益式听诊器，如图 2-4(b)。Littmann 3200 型电子听诊器由 3M 公司生产，功能包括：

（1）电子放大功能。Littmann 3200 具有内置的电子放大功能，可以将听到的心脏和肺部声音放大，帮助医生更容易地分辨细微的音频细节；环境消除技术：这款听诊器使用先进的环境消除技术，可以减少外部环境噪音的干扰，确保医生能够清晰地听到患者的生理音频；

（2）多种听诊模式。Littmann 3200 具有多个听诊模式，允许医生在不同频率范围内聆听心脏和肺部音频，以获取更全面的临床信息；记录和传输功能：这款电子听诊器通常配备有记录和传输功能，使医生能够记录患者的听诊结果，并在需要时将其传输到电脑或电子健康记录系统中。

两款产品都是符合 YY/T 1035-2021《听诊器》行业标准的成熟产品，Littmann 3200 型电子听诊器甚至完成了 FDA 与 HIPAA 认证。艾医吉昌 ETZ-1 型的优点包括：价格低廉、音频质量佳、可以 3.5mm 直接输出信号，缺点在于没有单独的心音听诊模式。本文选择艾医吉昌 ETZ-1 型作为可穿戴手套的心音拾取器件。Littmann 3200 型电子听诊器的优点包括：作为金标准行业大量使用、有成熟的配套软件与算法、有多种听诊模式，缺点在于软件和算法不开源。本文选择 Littmann 3200 型电子听诊器作为金标准用以频响校准与数据采集，具体使用包

括：2.5 章频响曲线修正算法设计的验证设备、3.3 章降噪算法设计的数据集采集设备、3.5 章与 3.6 章的心衰听诊数据的采集设备。



(a) 艾医吉昌 ETZ-1 型电子听诊器



(b) Littmann 3200 型电子听诊器

图 2-4 心音采集硬件

2.4.2 硬件方案和听诊区域选择

一体式可穿戴手套的心音采集部分被设计对应二尖瓣听诊区域。位于中指正下方位置的艾医吉昌 ETZ-1 型电子听头在使用时需要先找到胸骨的位置，然后放置在被试者第五类肋间左缘，即二尖瓣听诊区。

除了二尖瓣，主要的听诊位置还包括主动脉瓣区域、三尖瓣区域、肺动脉瓣区域等，如表 2-5 所示。心脏产生的声音主要是由心脏瓣膜的开合和血液流动引

起的。在心音听诊中，医生通常会将听诊器的膜片或钟形部分放在特定的胸部区域，以便更清晰地听到心脏产生的不同音频。最终选取二尖瓣区作为主听诊器的原因包括：

（1）更容易与心电采集点位配合。如图 2-1 所示，本设备需要使用 V1~V6 的胸部导联采集点。倘若选取肺动脉听诊区或主动脉听诊区，一体式可穿戴手套在使用时需要倒置，选取二尖瓣听诊区听诊可以方便直面被试者。

（2）心脏声音更清晰。二尖瓣位于心脏的左心室和左心房之间，相对于胸部表面较浅，因此通过胸壁可以相对容易地听到二尖瓣区域的心音。

（3）更容易分辨心衰。二尖瓣区域是心脏病变的常见发生地点之一。例如，二尖瓣关闭不全和二尖瓣狭窄等病变常常会产生特征性的心音，因此医生经常需要在这个区域进行听诊以辨认和评估病变。

表 2-5 常用心音听诊区域对应心脏瓣膜位置

名称	位置	对应心脏位置
二尖瓣区域	胸骨左缘的第五肋间空隙	用于听取二尖瓣的声音，对应于心脏的左心室
主动脉瓣区域	胸骨右缘的第二肋间空隙	用于听取主动脉瓣的声音，对应于心脏的左心室
三尖瓣区域	胸骨左缘的第四肋间空隙	用于听取三尖瓣的声音，对应于心脏的右心室
肺动脉瓣区域	胸骨左缘的第二肋间空隙	用于听取肺动脉瓣的声音，对应于心脏的右心室

心电信号经由 AD8232 芯片电路采集得到模拟信号，使用 STM32F7671GT6 作为主控芯片进行模数转换（Analog-to-Digital Converter, ADC）采集。步骤如下：

（1）配置外部时钟与分频器。STM32F7671GT6 包含 3 路模数转换（Analog to Digital Converter, ADC），最大工作频率 36MHz。使用 STM32F7671GT6 的 108MHz 外部时钟，设置 4 分频，得到 27MHz 的分频时钟。

（2）配置 ADC 时钟。根据分频器的设置，将 27MHz 分频时钟作为 ADC 的时钟源。在 ADC 控制寄存器（ADC_CR2）中进行配置。

（3）配置 ADC 采样模式。设置 ADC 为独立模式，以确保每个 ADC 通道的转换是独立进行的。在 ADC 控制寄存器（ADC_CR1）中进行配置。

（4）设置采样时间。STM32F7671GT6 的 ADC 转换时间=采样时间+12 个周期。设置采样时间为 3 个周期，得到转换时间为 15 个周期，即 0.55us。

（5）启动 ADC 采集。

(6) 获取结果并数据处理。设置每 10 次采样输出一次平均值结果，采样率降低 10 倍以提高精度。

2.5 前处理方案

2.5.1 心音频响曲线修正算法

本文在心音修正部分的目的是让所使用的艾医昌吉 ETZ-1 型电子听诊器的频响曲线尽可能接近 Littmann 3200 型电子听诊器。

YY/T 1035-2021《听诊器》种规定：听诊器传声特性的频率响应，即在规定的测试声源条件下，听诊器传声的输出声压级随测试声源频率的变化。对于声衰减式的听诊器，听头外径 35mm 以内，100Hz-500Hz 内的衰减应该不大于 30dB，500Hz-1000Hz 内的衰减应该不大于 25dB。对于声增益式的听诊器，最大增益输出时的声场压级应该不大于 132dB，等效输入噪声级应该不大于 32dB。本文使用了艾医昌吉 ETZ-1 型与 Littmann 3200 型在同一被试者二尖瓣听诊区的同步采集结果，共采集六次，每次一分钟。

电子听诊器的音频 EQ 曲线应该与采集对象相适应。心音的主要频段在 20Hz-200Hz。肺音的主要频段在 100Hz-500Hz。Littmann 3200 型听诊器有三种听诊模式：心音听诊、肺音听诊、心肺音听诊，对应三种不同的 EQ 均衡器设置。如图 2-5 所示，红色曲线是 Littmann 3200 型听诊器心音听诊模式下的频响曲线，20Hz-200Hz 是主要的听诊频段，在 150Hz 附近凹陷，大于 200Hz 部分缓慢降低。蓝色曲线是艾医昌吉 ETZ-1 型的频响曲线，因为没有设置心音听诊功能，所以频响曲线没有关注 20Hz-200Hz，而是在 300Hz 附近达到峰值然后衰减。较之 Littmann 3200 型，本文的频响修正算法目的包括：（1）增加 200Hz-1000Hz 频段的增益，达到 20dB；（2）削减因为 50Hz 工频干扰产生的 350Hz、400Hz、450Hz、500Hz、550Hz、600Hz、650Hz、700Hz 附近的突出。算法框图如图 2-5 所示。




图 2-5 频响曲线修正流程框图

心音信号是一个时域信号，表示随时间变化的声音。为了理解其频谱特性，需要将其转换为频域信号。通过傅立叶变换将时域信号分解为不同频率的成分，

产生频域表示，其中包含了信号在不同频率上的能量分布，如式 2-1 所示。通过分析频域表示，可以得到音频信号的频响曲线。频响曲线显示了在不同频率上的振幅或能量分布。不同频率上的振幅水平直接影响听感，而不同音响设备或录音环境也可能导致频响不均匀。

$$X(k) = \sum_{n=0}^{N-1} x[n] \cdot e^{-j2\pi kn/N} \quad (2-1)$$

其中 $x[n]$ 代表离散时序信号。

滤波器函数表示通常使用传递函数来描述，其中 $H(f)$ 是滤波器在频率域上的响应。传递函数通常可以表示为有理多项式的比值，对于巴特沃斯滤波器，其传递函数如式 2-2 所示。

$$H(f) = \frac{1}{\sqrt{1 + \left(\frac{f}{f_c}\right)^{2n}}} \quad (2-2)$$

其中， $H(f)$ 是截止频率，单位是 Hz； n 是滤波器的阶数。

均衡器（Equalizer）是一种用于调整音频频谱的工具，允许配置不同的滤波器组合，实现增强或削弱不同频率范围的音频信号。均衡器通常分为图形均衡器（Graphic Equalizer）和参数均衡器（Parametric Equalizer）两种类型。参数均衡器的传递函数通常如式 2-3 所示。

$$H(s) = \frac{G \cdot (s^2 + \omega_0^2)}{s^2 + \frac{\omega_0}{Q} \cdot s + \omega_0^2} \quad (2-3)$$

其中 G 是增益； ω_0 是中心频率，单位是 Hz； Q 是品质因数，即带宽与中心频率之比。

本文使用使用了 `scipy` 库 `signal` 包中的 `butter`、`lfilter`、`welch` 与 `pydub` 包的 `playback` 等方法完成了艾医吉昌 ETZ-1 型的参数均衡器设置，如图 2-6 所示，20Hz-200Hz 频段保持增益基本不变，200Hz-1000Hz 频段达到接近红色 Littmann 3200 型的增益水平。

对 50Hz 倍数频段的限波，包括 350Hz、400Hz、450Hz、500Hz、550Hz、600Hz、650Hz、700Hz，旨在削减交流电磁产生的干扰噪音。参考式 2-2，设置巴特沃斯带阻滤波器。以 350Hz 为例，希望截止频率设置在 350Hz 附近，角频率则为 $2\pi \times 350$ ，则带阻滤波器的传递函数如式 2-4 所示。

$$H(s) = \frac{1}{\sqrt{1 + \left(\frac{s}{j \cdot 2\pi \times 350}\right)^{2n}}} \quad (2-4)$$

其中, s 是复频域变量, j 是虚数单位, n 是滤波器的阶数。

本文使用使用了 `scipy` 库 `signal` 包中的 `butter`、`lfilter`、`welch` 等方法 350Hz、400Hz、450Hz、500Hz、550Hz、600Hz、650Hz、700Hz 附近的限波处理。




图 2-6 频响曲线修正结果

2.5.2 上位机采集软件

本文在上位机软件部分的目标包括:

- (1) 心电与心音同步采集功能。
- (2) 封装频响曲线修正算法。
- (3) 心电信号保存、心音信号保存、采集者信息保存。

本软件使用的编程语言是 Python, 图形框架使用的是 PyQt5, 音频 API 接口使用的 `sounddevice` 库, 串口 API 接口使用的是 `serial` 库。软件运行环境是: CPU 为 Intel Core i7-9700 CPU @3.60GHz, 内存为 DDR4 32G。

心电信号经由 AD8232 芯片电路采集得到模拟信号, 使用 STM32F767IGT6 作为主控芯片进行 AD 采集。ADC 位数为 12 位, 参考电压为 3.3V, 实际采集电压结果如式 2-5 所示。

$$V_{analog} = V_{digital} \cdot \frac{1}{2^{12}} \cdot 3.3 V \quad (2-5)$$

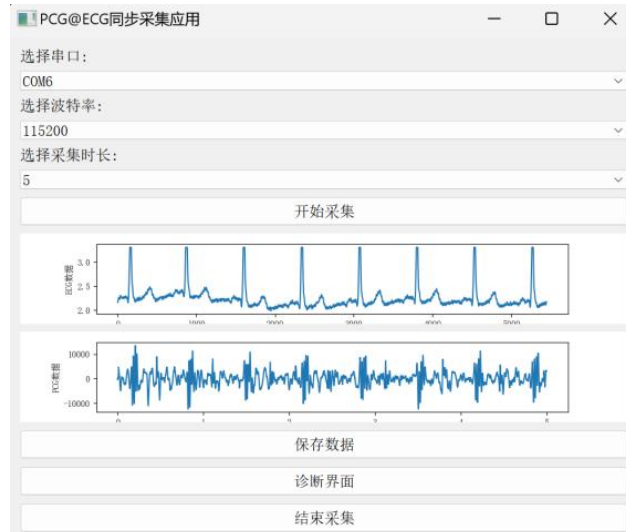
V_{analog} 为实际采集电压，单位是 V； $V_{digital}$ 为 ADC 输出结果。

将采集结果经由串口（Universal Synchronous/Asynchronous Receiver/Transmitter, Usart）与上位机通讯。设置波特率为 115200，输出字长为 8 位，停止位为 1，无奇偶校验位。

心音信号经由艾医昌吉 ETZ-1 型电子听诊器的 3.5mm 输出头可以与上位机板载声卡直接连接，设置音频采样率为 22k。

如图 2-7 (a)所示，选择下拉菜单，调用 PyQt5.QtSerialPort 的 QSerialPortInfo 方法获取当前可用 COM 设备。选择通信串口与通信波特率，如 COM6、115200。选择采集时长：5s、10s、15s。点击“开始采集”按键，开始采集。采集完成后，绘制心电与心音的预览图。

如图 2-7 (b)所示，数据备注与保存界面。在“病人信息”界面输入姓名、性别、年龄、ID。在“BNP 指数”界面输入被试者生化指标参数。在“过往病史”界面输入被试者可能的并发症，如心梗、高血压、肺气肿。在“入院原因”界面输入入院时间与入院方式，如 XX 年 XX 月 XX 日经由救护车入院。点击“保存数据”，保存为三个文件：“日期+年龄+性别+心电数据.csv”、“日期+年龄+性别+心音数据.wav”、“日期+年龄+性别+病理数据.csv”。“日期+年龄+性别+心电数据.csv”包含数据表头：“采集时间”、“采集时长”、“心电模拟值”、“姓名”、“性别”、“年龄”、“心音数据保存位置”、“病理数据保存位置”。“日期+年龄+性别+心电数据.csv”包含数据表头：“采集时间”、“采集时长”、“姓名”、“性别”、“年龄”、“BNP 指数”、“过往病史”、“入院原因”、“心电数据保存位置”、“心音数据保存位置”。



(a) 采集界面



(b) 数据保存界面

图 2-7 上位机软件界面

2.6 本章小结

本章的工作是针对急性心衰智能快速听诊的硬件设计，工作内容包含硬件设计、配套算法设计、配套软件界面设计，最终实现了心音与心电的同步采集、处理与数据保存。

硬件部分设计了心音采集硬件与心电采集硬件。心音硬件部分，选择了艾医昌吉 ETZ-1 型电子听诊器作为采集硬件，选择了单二尖瓣区作为听诊区。心电选择了 AD8232 作为主控芯片，选择了 V1、V4、LL 三区域作为心电采集区，选择了 STM32F767 芯片的外部 ADC 作为模数转换设备。安全性、电磁兼容性、生物相容性、环境适应性符合相关国家标准的基本要求，后续可以进一步具体认证。

算法部分设计了心音设备在心脏听诊模式下的频响曲线修正。参考国标 YY/T 1035-2021《听诊器》，以 Littmann 3200 型电子听诊器作为金标准，完成了艾医昌吉 ETZ-1 型电子听诊器的频响曲线修正，从心音、肺音的全频段听诊转变为心音听诊模式。

软件部分包含：心电与心音同步采集、生理数据和被试者信息保存。使用 Python 语言与 PyQt5 框架完成了图像界面绘制、算法封装、线程调度与数据保存。

较之李凤^[57]和向梦辉^[58]的研究，本文的方案引入了心电信息辅助心音的采集，有利于后续开展心电-心音双模态智能分析。和李凤^[57]的研究一样，本文同样采用了成熟的商业音频拾取探头，通过频响曲线修正，本文实现了和 Littmann 3200 电子听诊器一致的心音听诊模式。较之向梦辉^[58]的研究，本文没有采用模拟滤波，对采集信号的处理主要是调用封装在软件中的数字滤波方法，方便后续算法调试与更新。

第3章 轻量级心衰听诊模型研究

3.1 引言

第二章介绍了本文硬件设计方案以及具体实现过程。本章的工作是针对临床急性心衰的快速听诊需求，开发一种自动诊断算法。工作内容包括：数据集的建立，心音的预处理，诊断模型的开发，听诊策略的开发。具体完成了四部分工作：

首先，如图 3-1(a)所示，搜集建立两个数据集，用以诊断模型开发的心衰数据集与用以降噪算法开发的降噪数据集。使用一个 Yassen 公开数据集^[62]用以评估模型泛化能力。

然后，如图 3-1(b)所示，开发心音预处理算法，包括基于小波变换（Wavelet Transform, WT）的降噪算法与基于梅尔频率倒谱系数（Mel Frequency Cepstrum Coefficient, MFCC）的特征提取。

再次，如图 3-1(c)所示，提出了一个 DenseHF-Net 心衰听诊诊断模型。与经典卷积神经网络比较，并于公开数据集上测试泛化能力。

最后，提出了两种心衰听诊策略。如图 3-1(d)所示，适用初筛与急诊的二尖瓣单域听诊策略，使用了二尖瓣单个听诊区。如图 3-1(e)所示，适用病房筛查与监护场景的多域融合听诊策略，使用了二尖瓣、主动脉瓣、肺动脉瓣三个听诊区。

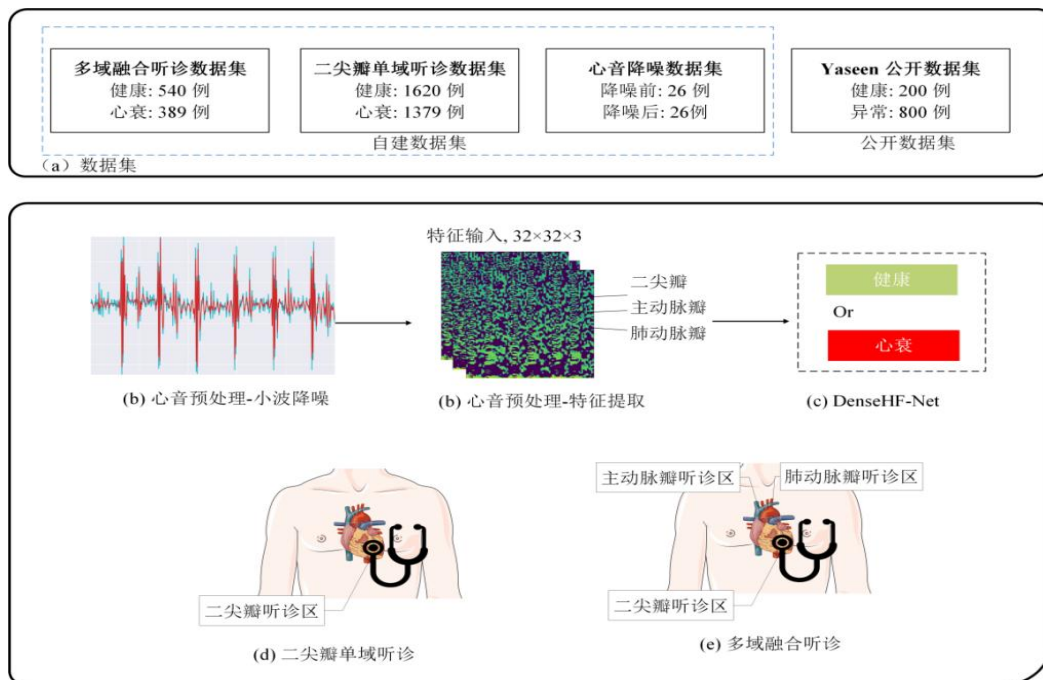


图 3-1 轻量级心衰听诊框图

3.2 数据集建立

3.2.1 二尖瓣听诊数据集

心音数据库是在天津市第四中心医院于 2022 年至 2023 年间陆续完成临床采集、数据清洗及标注审核等工作。数据使用 3M Littmann3200 电子听诊器采集的，采样率设置为 22kHz。本研究已经获得了天津市第四中心医院医学伦理委员会的批准（No. 2022-T050），所有志愿者都已签署知情同意书。

在两位主任医师的指导下，从不同科室的心力衰竭患者中收集心音，构建了一个心衰听诊数据集。招募被诊断为心力衰竭的患者作为志愿者，在三个不同的部位记录听诊，并同时记录了他们的性别、年龄、住院信息、病史以及最新的生化标志物。主任医师对数据进行审查，排除了那些已经从心力衰竭中康复或心力衰竭特征不明确的样本。以同样的方式收集了来自健康人群的心音，以作为对照组。如表 3-1 所示，心力衰竭听诊数据集包括总计 71.6 分钟的心力衰竭听诊和 81 分钟的对照组听诊。如表 3-2 所示，数据采集辗转六类科室完成，包含急救科室和心内科。

二尖瓣听诊数据集包括 1620 例健康病例和 1379 例心力衰竭病例，每个病例的音频记录持续 3~5 个心动周期。与之前的数据集类似，构建 10 折交叉验证。

表 3-1 心衰数据集志愿者信息

类型	性别	年龄 ($\bar{x} \pm sd$)	采集时长 (分钟)
心衰	男性	72.6 \pm 12.0	34.8
心衰	女性	77.9 \pm 11.1	36.8
健康	男性	24	27.0
健康	女性	26 \pm 2	54.0

表 3-2 心衰被试者具体信息

科室	数量	LVEF ($\bar{x} \pm sd$)	BNP ($\bar{x} \pm sd$, pg/ml)
急救室	3	null	null
急诊综合	33	53.4 \pm 9.3	4274.1 \pm 6565.1
CCU	23	52.3 \pm 10.0	3597.0 \pm 2673.6
心内一	10	36.3 \pm 7.4	8239.0 \pm 6694.8
心内二	3	43.4 \pm 8.6	16342.3 \pm 7586.5
心内三	14	40.3 \pm 9.2	4131.5 \pm 6441.3

表 3-3 降噪数据集详情

类型	采集时长（秒）
3 级柔和吹风样收缩期杂音	68
S1 强弱不等	23
主动脉瓣狭窄-功能性	4
乐音样杂音	23
二尖瓣关闭不全-器质性	59
二尖瓣狭窄-功能性	9
二尖瓣狭窄 - 器质性	9
二联律	39
反常分裂	13
固定性 S2 分裂	12
室间隔缺损	9
开瓣音	10
收缩中、晚期喀喇音	9
相对性二尖瓣关闭不全	4
窦性心动过缓	7
窦性心动过速	4
第一心音减弱	3
第一心音分裂	4
第一心音增强	6
第二心音减弱	29
功能性肺动脉瓣关闭不全	3
肺动脉瓣狭窄-收缩期喀喇音第二心音分裂	67
舒张期四音律	15
连续性杂音	15
重叠性奔马律	15
钟摆律	6

3.2.2 多域融合听诊数据集

多域融合听诊数据集包括 540 例健康病例和 389 例心力衰竭病例。每个病例包括二尖瓣、主动脉瓣和肺动脉瓣的三个音频记录。为确保结果的稳健性，我们在进行数据乱序后建立了 10 折交叉验证数据库。

3.2.3 心音降噪数据集

本文创建了一个降噪对比数据集，涵盖了 26 个不同的病理描述。最初的 26 例常见的病理心音。如表 3-3 所示，类型包括：二联律、开瓣音、奔马律、钟摆律等。与之匹配的是 26 例降噪心音，由两位医学主任医师进行审查和验证。降噪效果如图 3-2 所示，在消除背景噪音的同时保留所有病理信息。

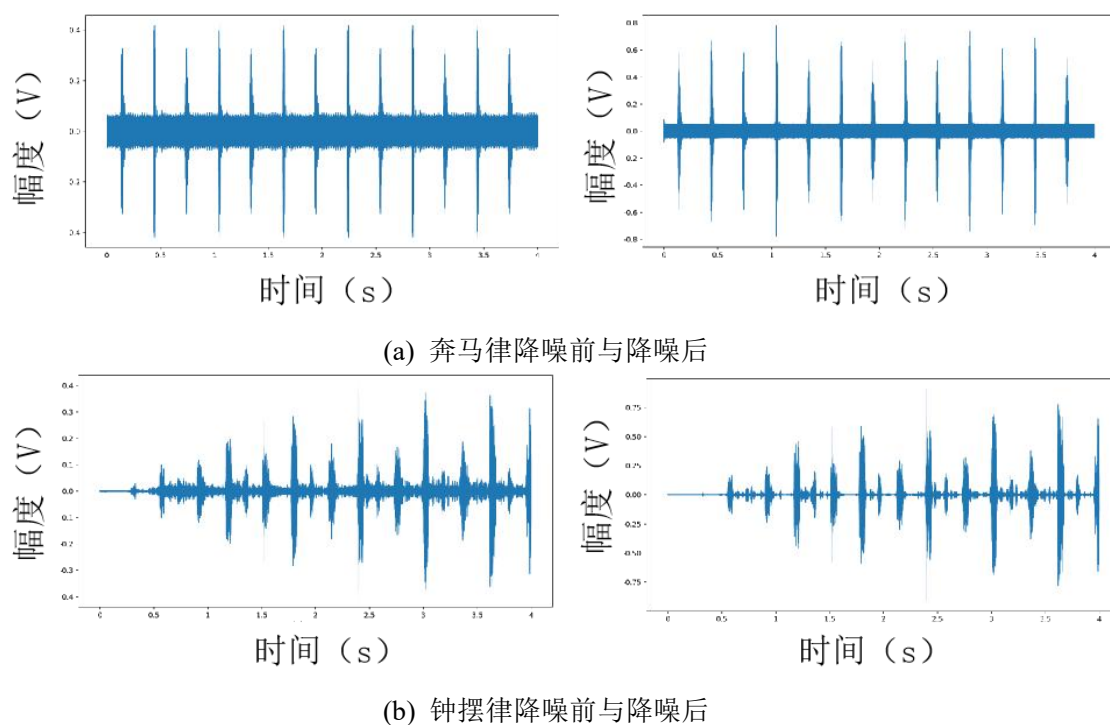


图 3-2 降噪数据集部分波形

3.2.4 心音公开数据集

表 3-4 公开数据集

类型	数量
主动脉瓣狭窄 (Aortic Stenosis)	200
二尖瓣返流 (Mitral Regurgitation)	200
二尖瓣狭窄 (Mitral Stenosis)	200
二尖瓣脱垂 (Mitral Valve Prolapse)	200
正常 (Normal)	200

本文使用了一个 Yaseen 公开心音数据集^[62]。如表 3-4 所示，数据类型包括主动脉瓣狭窄 (Aortic Stenosis, AS)、二尖瓣返流 (Mitral Regurgitation, MR)、

二尖瓣狭窄（Mitral Stenosis, MS）、二尖瓣脱垂（Mitral Valve Prolapse, MVP）和正常（Normal, N）。每类有 200 例，每例时长为 3s。主要目的是评估模型在诊断正常和异常心音方面的泛化能力。80%的数据用以训练，余下 20%用以测试。

3.3 心音的预处理

3.3.1 心音的小波降噪

心音信号的预处理旨在抑制临床环境中的噪音背景。小波变换用于基于母小波，如 Haar、db、Coif、Sym 和 Biorthogonal（bior）等，降低心音的噪音。Chen 等人^[72]使用 db6 小波基实现了最佳的降噪效果。Zhao 等人^[73]使用 bior 5.5 的基础上得到最佳结果。Cheng 等人^[74]利用基于小波的自适应算法增强了心脏信号的降噪效果，与预降噪状态相比，信号改善了 12.4 dB。

本文考虑了三个小波函数：db6、sym8 和 coif5。这些小波基用于心音录音的离散小波分解。在分解之后，进行离散小波重构，其中在最大硬阈值模 20% 处应用系数收缩函数。

其次，为了确定系数收缩策略，在离散小波分解和重构过程中采用了各种系数收缩函数。

本文提出了一个新颖的自适应阈值函数 $f_{self}(x)$ ，如式 3-1 所示。

$$f_{self}(x) = \begin{cases} e^{\frac{x+T}{2}} - e^{\frac{-x-T}{2}}, & x \leq -T \\ 0, & -T \leq x \leq T \\ e^{\frac{x-T}{2}} - e^{\frac{-x+T}{2}}, & x \geq T \end{cases} \quad (3-1)$$

其中，T 代表阈值宽度。

$f_{self}(x)$ 有如下优点：

(1) $f_{self}(x)$ 满足：

$$\lim_{x \rightarrow -T^-} f_{self}(x) = \lim_{x \rightarrow -T^+} f_{self}(x) = 0$$

$$\lim_{x \rightarrow T^-} f_{self}(x) = \lim_{x \rightarrow T^+} f_{self}(x) = 0$$


$f_{self}(x)$ 在 $x = \pm T$ 阈值边缘具有可导性。

(2) $f_{self}(x)$ 对任意 $\varepsilon \in [-\infty, \infty]$ 满足：

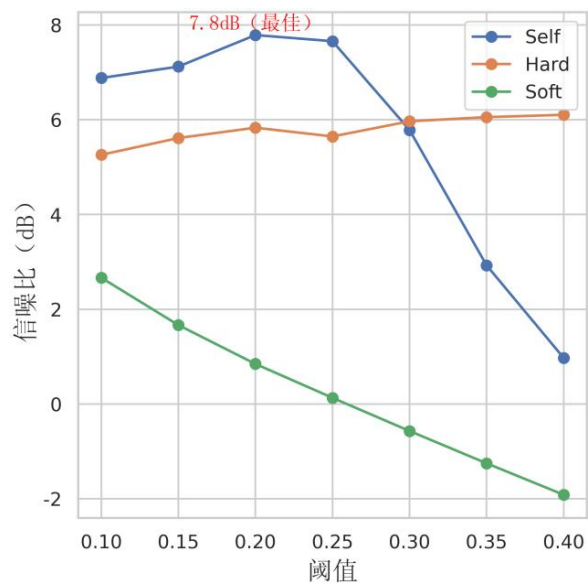
$$f_{self}(\varepsilon) + f_{self}(-\varepsilon) = 0$$

$f_{self}(x)$ 是奇函数，曲线平滑并且单调递增。

(3) $f_{self}(x)$ 克服了硬阈值函数的阈值边界不连续问题，在消除背景噪音的基础上最大程度保留心音细节。



(a) 小波基与分解层数的选择



(b) 阈值函数与阈值选择


图 3-3 小波降噪选择过程

为了确定小波基和分解层数，首先使用硬阈值函数作为收缩函数，测试 Db6、Coif5、Sym8 小波基在 4 层、5 层、6 层、7 层、8 层离散小波分解的平均信噪比。如图 3-3，Sym8 基于 7 层分解水平提供了最有效的去噪结果。


在保持 Sym8 基于 7 层分解水平的情况下，通过不同的收缩函数和阈值值来获取平均信噪比。计算结果表明，使用 20% 模最大阈值的 $f_{self}(x)$ 函数的组

合是最优的去噪方法。

如图 3-4 所示，在降噪后的波形中，噪声部分的幅度明显降低，音频信号的清晰度和整体质量可能会有所提高。功率谱表示了音频信号在频率域上的能量分布情况。在原始音频中，噪声通常会在某些频率上产生较高的能量峰值，降噪处理旨在减少这些噪声能量。在降噪后的功率谱中，噪声频率上的能量峰值明显降低，整体能量分布可能会更加平滑。



(a)降噪前后波形对比



(b)降噪前后功率谱对比

图 3-4 心音降噪结果

本文对于用于短心音去噪的最佳分解层数、小波基和阈值收缩函数进行了深入研究。基于 sym8 小波 $f_{\text{self}}(x)$ 的 20% 阈值进行 7 层分解可以获得最有效的去噪效果。值得注意的是，虽然 Db6 和 sym8 小波具有类似的性质，但是由于 sym8

小波具有较短的支持长度和更优秀的能量集中性，因此与心音形态更加一致。

与 Chen 和 Zhao^[72-73]的研究相比，本文采用信噪比作为主要指标来评估噪声降低，避免了波形比较的局限性。此外，我们的去噪实验涵盖了 26 种病理性心音，增强了我们研究结果的临床相关性。此外，与 Cheng^[74]相比，我们提出了一种新的 $f_{self}(x)$ 构建方法，可以显著提高 SNR（7.8 dB）。

3.3.2 心音的特征提取

心音的特征提取工程旨在减少数据的维度，突出关键信息，从而改善后续的数据处理和分析。梅尔频谱（Mel Spectrum）和梅尔频率倒谱系数（Mel Frequency Cepstrum Coefficient, MFCC）被广泛采用作为语音识别中的特征提取方法。人耳对自然声音的非线性反应，较之高频信号对低频信号更敏感。如式 3-2 所示，是梅尔频谱技术公式。

$$Mel(f) = 2595 \ln \left(1 + \frac{f}{700} \right) \quad (3-2)$$

频率信号 f 和 $Mel(f)$ 单位都是 Hz。梅尔尺度对频率信号 f 变换得到的 $Mel(f)$ 更符合人耳听感。

为了在数字信号处理中再现梅尔尺度，设计多个梅尔滤波器，一般为 26 个。如式 3-3 所示，是梅尔滤波器设计公式。

$$H_m(k) = \begin{cases} \frac{k - f(m-1)}{f(m) - f(m-1)}, & f(m-1) \leq x \leq f(m) \\ \frac{f(m+1) - k}{f(m+1) - f(m)}, & f(m) \leq x \leq f(m+1) \\ 0, & others \end{cases} \quad (3-3)$$

单个梅尔滤波器是单个三角滤波器，取中心频率 $f(m)$ 。每单个滤波器随 m 取值越大而增宽。低频部分部署密集滤波器组，高频部分稀疏，以拟合梅尔尺度。

使用梅尔滤波器组与功率谱相乘，得到梅尔频谱，如式 3-4。

$$MelSpec(m) = \sum_{k=f(m-1)}^{f(m+1)} H_m(k) \cdot |X(k)|^2 \quad (3-4)$$

人耳对声音响度的感受也是非线性，因此计算滤波器组后的对数能量，如式 3-5。

$$S(m) = \log \left(\sum_{k=0}^{N-1} |X_a(k)|^2 \cdot H_m(k) \right), 0 \leq m \leq M \quad (3-5)$$

对取对数后的梅尔频率谱进行离散余弦变换，得到梅尔频率倒谱系数，如式3-6。

$$C(n) = \sum_{m=0}^{N-1} S(m) \cos \left(\frac{\pi n(m-0.5)}{M} \right), n = 1, 2, \dots, L \quad (3-6)$$

离散余弦变换有助于将信号的能量集中在少量的系数上，通过将信号在频域中的表达方式变得更加集中。离散余弦变换也改变了信号在频域的表达方式，降低了维度。

本文的 MFCC 特征设计定义与 Wu 等人^[64]的研究相同，并且在时频提取效果上与 Vepa^[63]的方法取得了相同的效果。




图 3-5 心音特征提取结果图

如图 3-5 所示，正常心音与二尖瓣脱垂患者的心音示例。梅尔频谱和 MFCC 表示涵盖了一系列波形特征，有效地捕获了高频信号特征的复杂性，以热力图的形式呈现。

本文深入探讨了特征提取的复杂性，特别关注梅尔频谱和 MFCC。用于心音的 MFCC 特征提取方法具有保存时间波形特征和捕获频率能量分布的优势。这种方法保留了与梅尔尺度相一致的宝贵信息，该标度对应于人类听觉感知。

3.4 DenseHF-Net 心衰诊断模型

3.4.1 DenseHF-Net 模型总体结构

心音诊断常见的深度学习模型架构包括卷积神经网络（Convolutional Neural Network, CNN）、循环神经网络（Recurrent Neural Network, RNN）、长短期记忆网络（Long Short-Term Memory, LSTM）和卷积神经网络-长短期记忆网络混合模型（Convolutional Neural Network - Long Short-Term Memory, CNN-LSTM）^[65-68]。本文着重于针对急性心力衰竭（AHF）的快速诊断而设计的模型，旨在开发一个既具有轻量级特性又具有一定精确度的模型。

针对轻量计算的临床需求，本文基于 CVPR 2017 最佳论文 Dense-Net^[77]开发了心衰听诊识别网络 DenseHF-Net。为了实现模型的轻量化，DenseHF-Net 仅采用了四个 Dense 块：DenseBlock-1、DenseBlock-2、DenseBlock-3 和 DenseBlock-4。这个选择减少了模型的参数数量和计算负载，同时仍保持了一定的深度和特征提取能力。同时采用三个具有较小压缩率的过渡层来同时减少 1x1 卷积层的输出通道数，从而减小特征图的大小。最终，通过一个线性层获得诊断结果，如图 3-6 所示。

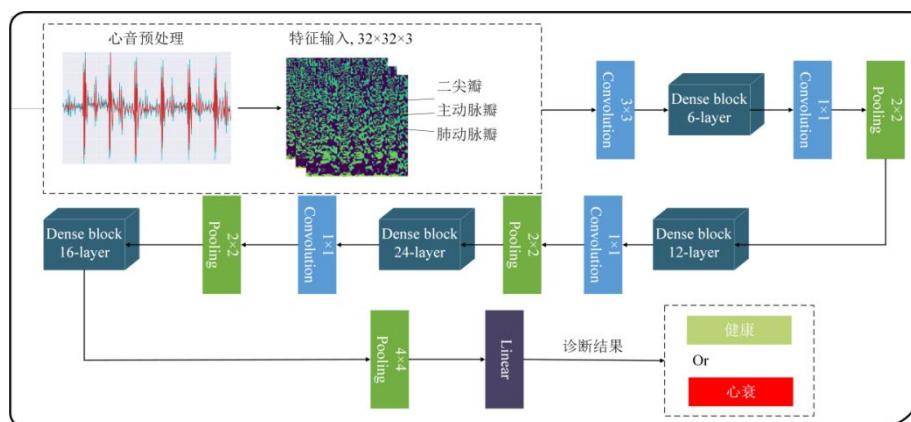


图 3-6 DenseHF-Net 结构示意图

具体结构如表 3-5 所示。首先,特征工程结果经由特征映射得到一个 32×32 大小的输出。然后,经由四次的密集块 (Dense Block) 与过渡层 (Transition Layer) 计算。Dense Block 结构见 3.4.2 Dense Block 子模块。Transition Layer 通常由 1×1 卷积层和 2×2 的平均池化层组成,可以控制特征图的尺寸减少程度。在密集块之间使用过渡层来降低特征图的维度,减少参数量和计算量。接着,经由一次 Dense Block 计算与池化计算 (Pooling Layer) 后得到 $1 \times 1 \times 384$ 的输出。最后,经由一次线性层 (Linear Layer) 计算,得到 1×2 的输出结果,即是否心衰的二分类结果。

表 3-5 DenseHF-Net 网络结构

基本结构	卷积核	输出大小
Feature Map	$[3 \times 3, 24] \times 1$	32×32
Dense Block	$\begin{bmatrix} 1 \times 1, 48 \\ 3 \times 3, 12 \end{bmatrix} \times 6$	32×32
Transition	$\begin{bmatrix} 1 \times 1, \text{conv} \\ 2 \times 2, \text{pool} \end{bmatrix}$	16×16
Dense Block	$\begin{bmatrix} 1 \times 1, 48 \\ 3 \times 3, 12 \end{bmatrix} \times 12$	16×16
Transition	$\begin{bmatrix} 1 \times 1, \text{conv} \\ 2 \times 2, \text{pool} \end{bmatrix}$	8×8
Dense Block	$\begin{bmatrix} 1 \times 1, 48 \\ 3 \times 3, 12 \end{bmatrix} \times 24$	8×8
Transition	$\begin{bmatrix} 1 \times 1, \text{conv} \\ 2 \times 2, \text{pool} \end{bmatrix}$	4×4
Dense Block	$\begin{bmatrix} 1 \times 1, 48 \\ 3 \times 3, 12 \end{bmatrix} \times 16$	4×4
Pooling	4×4	$1 \times 1 \times 384$
Linear		1×2

3.4.2 Dense Block 子模块

如图 3-7 所示,密集块 (Dense Block) 由多个卷积层组成,每个卷积层的输入是前面所有层的特征图的串联,输出则是所有层特征图的串联。卷积层包括批量归一化 (Batch Normalization) 和激活函数 (如 ReLU),以增强网络的训练稳定性和非线性拟合能力。

DenseHF-Net 使用了四个 Dense Block 结构,包括卷积层、池化层、全连接层等总计 121 层。四次 Dense Block 结构的 BN-ReLU 卷积次数分别是 6 次、12

次、24 次、16 次。每一层都与前面的所有层进行密集连接，这意味着每一层都可以直接访问到之前所有层的特征信息。密集连接使得特征在网络中的传播更加充分，有助于提取更丰富和抽象的特征。

DenseHF-Net 的设计使得特征在传播过程中得到了保留和增强，有助于提取更丰富的特征。同时，DenseHF-Net 的 121 层轻量设计适合于计算资源有限下的图像分类等任务。

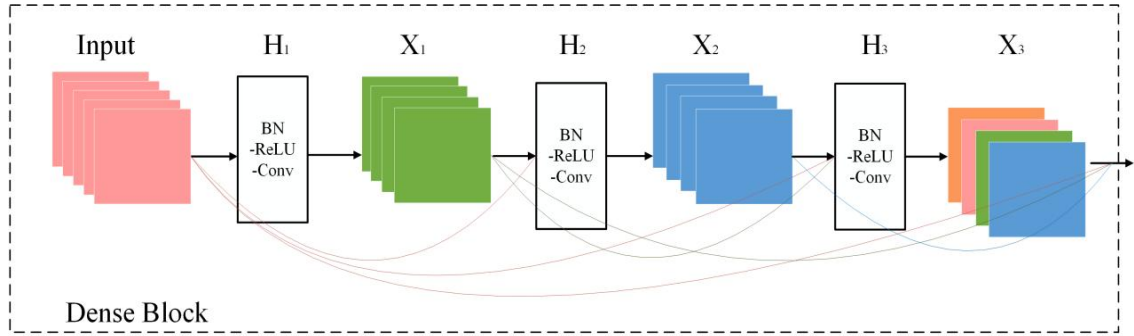


图 3-7 Dense Block 结构示意图

3.4.3 同类网络模型比对分析

为了测试 DenseHF-Net,经典的 ResNet^[75]和 MobileNet^[76]模型也进行了训练。ResNet-18 的网络设计见表 3-6。MobileNetV1-28 的网络设计见表 37。所有输入特征都调整为 32×32 ，以便于移动终端的使用。三个模型的参数数量分别为 3.82M、42.61M 和 12.24M。这三个模型的内存访问成本 (MAC) 分别为 130.89M、556.97M 和 46.28M。

表 3-6 ResNet-18^[75]网络结构

基本结构	卷积核	输出大小
Feature Map	$[3 \times 3, 64] \times 1$	32×32
Conv2_x	$\begin{bmatrix} 3 \times 3, 64 \\ 3 \times 3, 64 \end{bmatrix} \times 2$	32×32
Conv3_x	$\begin{bmatrix} 3 \times 3, 128 \\ 3 \times 3, 128 \end{bmatrix} \times 2$	16×16
Conv4_x	$\begin{bmatrix} 3 \times 3, 256 \\ 3 \times 3, 256 \end{bmatrix} \times 2$	8×8
Conv5_x	$\begin{bmatrix} 3 \times 3, 512 \\ 3 \times 3, 512 \end{bmatrix} \times 2$	4×4
Pooling	4×4	$1 \times 1 \times 512$
Linear		1×2

表 3-7 MobileNetV1-28^[76]网络结构

基本结构	卷积核	输出大小
Feature Map	$[3 \times 3, 32] \times 1$	30×30
Con_dw, pw	$\begin{bmatrix} 3 \times 3, 32 \\ 1 \times 1, 64 \end{bmatrix} \times 1$	30×30
Con_dw, pw	$\begin{bmatrix} 3 \times 3, 64 \\ 1 \times 1, 128 \end{bmatrix} \times 1$	15×15
Con_dw, pw	$\begin{bmatrix} 3 \times 3, 128 \\ 1 \times 1, 128 \end{bmatrix} \times 1$	15×15
Con_dw, pw	$\begin{bmatrix} 3 \times 3, 128 \\ 1 \times 1, 256 \end{bmatrix} \times 1$	8×8
Con_dw, pw	$\begin{bmatrix} 3 \times 3, 256 \\ 1 \times 1, 256 \end{bmatrix} \times 1$	8×8
Con_dw, pw	$\begin{bmatrix} 3 \times 3, 256 \\ 1 \times 1, 512 \end{bmatrix} \times 1$	4×4
Con_dw, pw	$\begin{bmatrix} 3 \times 3, 512 \\ 1 \times 1, 512 \end{bmatrix} \times 5$	4×4
Con_dw, pw	$\begin{bmatrix} 3 \times 3, 512 \\ 1 \times 1, 1024 \end{bmatrix} \times 1$	2×2
Con_dw, pw	$\begin{bmatrix} 3 \times 3, 1024 \\ 1 \times 1, 1024 \end{bmatrix} \times 1$	2×2
Pooling	2×2	$1 \times 1 \times 1024$
Linear		1×2

3.4.4 超参数设计与评价指标

为了降低过拟合可能，本文基于 torchvision 方法的 transforms.Compose 函数设计了特征输入的数据增强。步骤包括 40×40 放缩、 $\pm 15^\circ$ 随机旋转、 32×32 中心裁剪、numpy.ndarray 到张量的 ToTensor 转换、减去均值并除以标准差的均一化操作。

本文基于 torch.optim 方法设计了优化器、损失函数和学习率调度器。使用随机梯度下降（Stochastic Gradient Descent, SGD）作为优化器对象。学习率（Learning Rate, LR）被设置为 0.1。动量被设置为 0.9，较高的动量有助于加速模型在相关方向上的更新，以减少训练时间和提高模型性能。采用了 MultiStepLR 学习率调度器，通过设定特定的训练 epoch（10 和 15）来降低学习率。在第 10 和第 15 个 epoch 时，学习率将按照设定的 gamma=0.1 进行衰减，以帮助模型更好地收敛到最优解。

本文使用了准确率 (Accuracy, Acc)、敏感度 (Sensitivity, Se)、特异性

(Specificity, Sp)、F1 分数 (F1-Score)作为评价指标。公式定义如式 3-7、式 3-8、式 3-9、式 3-10。

$$Acc = \frac{TP + TN}{TP + FP + TN + FN} \quad (3-7)$$

$$Se = \frac{TP}{TP + FN} \quad (3-8)$$

$$Sp = \frac{TN}{TN + FP} \quad (3-9)$$


$$F1 - Score = 2 \times \frac{Se \times Sp}{Se + Sp} \quad (3-10)$$

3.4.5 实验环境与模型训练

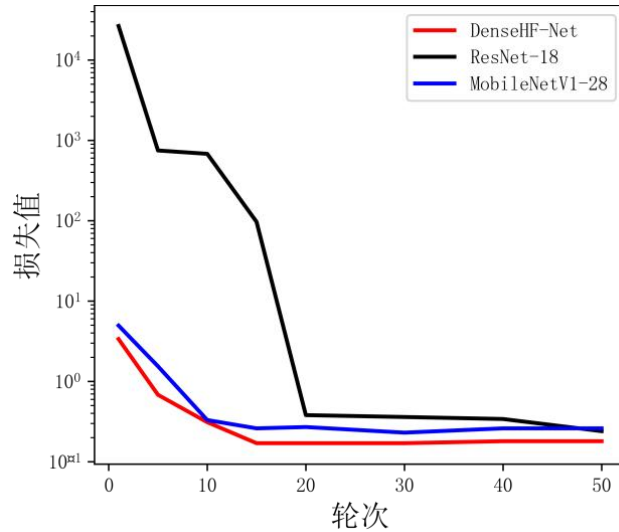
本文的实验环境如下：

系统：Ubuntu 18.04；CPU：Intel(R) Core(TM) i7-9700K CPU @ 3.60GHz；GPU：NVIDIA GeForce RTX 3090 with 24G VRAM；CUDA 版本：11.4；PyTorch 版本：1.10。

如图 3-8 所示，是二尖瓣单域听诊策略下的模型拟合情况。值得注意的是，ResNet-18 和 MobileNetV1-28 表现出相当的性能，而 DenseHF-Net 准确率提高速度最快。三个模型都实现了损失值的有效下降。ResNet-18 和 MobileNetV1-28 表现出类似的性能趋势，而 DenseHF-Net 展现出最快的收敛速度。



(a) 准确率随训练轮次变化



(b) 损失值随训练轮次变换

图 3-8 心尖单域听诊训练拟合情况

3.5 二尖瓣单域听诊策略

3.5.1 实验数据集

二尖瓣单域听诊仅使用了二尖瓣单个听诊区用以心衰诊断。本策略更加注重便捷性，旨在应急医疗服务（EMS）或常规筛查场景中使用。

数据集构建见 3.2.1 小节，二尖瓣单域听诊策略数据集包括健康 1620 例、心衰 1379 例。数据集不重复，不交叠。每例包括 10 秒以内二尖瓣区域听诊音频，

22kHz 采样。数据集乱序后进行构建十折交叉，进行十次实验，每次 90%数据用以训练，余下 10%用以测试。

3.5.2 实验结果分析

如表 3-8 所示，是二尖瓣单域听诊策略下的十折交叉测试集平均结果。DenseHF-Net、ResNet-18 和 MobileNetV1-28 的平均准确率分别为 93.63%、91.33% 和 90.73%。DenseHF-Net 的准确率比 ResNet-18 高 2.30%，比 MobileNetV1-28 高 2.90%。三个模型的平均敏感度分别是 94.28%、92.32%和 90.68%。DenseHF-Net 的敏感度比 ResNet-18 高 3.79%，比 MobileNetV1-28 高 5.43%。此外，三个模型的平均特异性分别测得为 92.95%、90.20%和 90.80%。DenseHF-Net 的特异性比 ResNet-18 高 1.80%，比 MobileNetV1-28 高 1.20%。三个模型的平均 F1 分数分别为 93.57%、91.17%和 90.69%。DenseHF-Net 的 F1 分数比 ResNet-18 高 2.78%，比 MobileNetV1-28 高 3.26%。

表 3-8 二尖瓣单域听诊结果

评价指标	DenseHF-Net	ResNet-18	MobileNetV1-28
Acc (average \pm sd, %)	93.63 \pm 0.96	91.33 \pm 2.48	90.73 \pm 1.80
Se (average \pm sd, %)	94.28 \pm 1.85	92.32 \pm 2.59	90.68 \pm 2.49
Sp (average \pm sd, %)	92.95 \pm 2.30	90.20 \pm 4.49	90.80 \pm 2.97
F1 – Score (average \pm sd, %)	93.57 \pm 0.89	91.17 \pm 2.58	90.69 \pm 1.75

3.5.3 模型泛化能力评估

本文基于 Yaseen 公开数据集^[62]的 1000 例五种标签的数据评估模型的泛化能力。构建了四类疾病数据集：主动脉瓣狭窄与正常、二尖瓣返流与正常、尖瓣狭窄与正常、二尖瓣脱垂与正常。80%数据用以训练，余下 20%用以测试。

如表 3-9 所示，是 DenseHF-Net、ResNet-18、MobileNetV1-28 三种模型在 Yaseen 公开数据集上的测试结果。三种模型都展现出对短时长心音识别的强大泛化能力。主动脉瓣狭窄的诊断表现最佳，三个模型的灵敏度和特异度均超过 82%。对于尖瓣狭窄和二尖瓣返流，所有三个模型都能正确诊断，ResNet-18 和 MobileNetV1-28 的灵敏度和特异度均超过 87%。然而，DenseHF-Net 对二尖瓣脱垂的诊断结果不佳，特异度仅为 30%，F1 分数仅为 45.88%。

表 3-9 公开数据集泛化评估结果

评价指标	DenseHF-Net	ResNet-18	MobileNetV1-28
Acc of AS (average, %)	91.25	92.50	82.50
Se of AS (average, %)	90.00	95.00	87.50
Sp of AS (average, %)	92.50	90.00	77.50
F1 – Score of AS (average, %)	91.23	92.43	82.20
Acc of MR ((average, %)	58.75	88.75	92.50
Se of MR (average, %)	97.50	80.00	87.50
Sp of MR (average, %)	20.00	97.50	97.50
F1 – Score of MR (average, %)	33.19	87.89	92.23
Acc of MS (average, %)	75.00	95.00	85.00
Se of MS (average, %)	75.00	90.00	87.50
Sp of MS (average, %)	75.00	100.00	82.50
F1 – Score of MS (average, %)	75.00	94.74	84.93
Acc of MVP (average, %)	63.75	83.75	88.75
Se of MVP (average, %)	97.50	80.00	87.50
Sp of MR (average, %)	30.00	87.50	90.00
F1 – Score of MVP (average, %)	45.88	83.58	88.73

3.6 多域融合听诊策略

3.6.1 实验数据集

多区域融合听诊策略使用了二尖瓣、主动脉瓣、肺动脉瓣三个听诊区，旨在缩短入院-球囊扩张时间，针对病房诊断、监护两种场景下急性心衰诊断的特定需求进行策略优化。从而实现降低心力衰竭患者的死亡率和再住院率。

数据集构建见 3.2.2 小节，多域融合听诊策略数据集包括健康 540 例、心衰 389 例。数据集不重复，不交叠。每例包括二尖瓣、主动脉瓣、肺动脉瓣三个听诊区的音频，22kHz 采样。数据集乱序后进行构建十折交叉，进行十次实验，每次 90%数据用以训练，余下 10%用以测试。

3.6.2 多模态特征融合

多区域融合听诊策略对二尖瓣、主动脉瓣、肺动脉瓣三个听诊区的梅尔频率倒谱特征张量进行早融合(Early fusion)后作为网络输入。单个听诊的特征谱图是三通道 32×32 大小，如图 3-1(b)所示。三个听诊区的特征即三张三通道谱图。对三个不同的听诊区域的特征施加不同权重。二尖瓣、主动脉瓣、肺动脉瓣三个听诊区的权重分别是 3: 1: 1。二尖瓣听诊区是最清晰，保留最多生理信息的听诊器，保留所有通道信息。主动脉瓣和肺动脉瓣听诊区的特征进行各通道均一化后的灰度矩阵张量作为辅助特征。最后得到 $[32 \times 32, 5]$ 的多模态融合特征。

3.6.3 模型参数量对比

如表 3-10 所示，展示了 DenseHF-Net、ResNet-18 和 MobileNetV1-28 的性能比较。使用了参数数量、内存访问成本以及前向/后向传递大小作为是评估模型轻量性指标。DenseHF-Net 的参数数量最少，仅为 3.82M，远低于 ResNet-18 的 42.61M 和 MobileNetV1-28 的 12.24M。这表明 DenseHF-Net 在模型大小方面具有优势，适用于资源有限的环境或需要轻量级模型的应用场景。

表 3-10 轻量级模型参数量比较

模型	参数量	内存访问成本	前向/后向传递参数大小
DenseHF-Net	3.82M	130.89 M	43.49M
ResNet-18	42.61 M	556.97M	13.63M
MobileNetV1-28	12.24 M	46.28M	10.31M

DenseHF-Net 具有较少的参数数量和相对较低的内存访问成本，使其成为移动设备上部署的理想选择。其设计注重轻量化，能够在计算资源受限的环境中高效运行，而不会过度消耗设备的处理能力和电池寿命。在临床应用中，数据可能会非常丰富和复杂，而 DenseHF-Net 作为一种密集连接的深度学习模型，具有较强的特征提取和表示能力，能够更好地适应和处理这种复杂的临床数据，从而提高模型的准确性和泛化能力。

综上所述，DenseHF-Net 作为一种轻量级且适应心衰急诊的神经网络模型，在临床移动端应用中具有很多优势。其设计的轻量化和高效性使其能够在移动端上高效运行，同时保护患者数据的隐私和安全性，因此在听诊移动端中是一个理想的选择。

3.6.4 实验结果分析

如表 3-11 所示,是多域融合听诊策略下的十折交叉测试集平均结果。在这 DenseHF-Net、ResNet-18、MobileNetV1-28 三个模型中, DenseHF-Net 实现了最高的性能,其次是 MobileNetV1-28 和 ResNet-18。DenseHF-Net、ResNet-18、MobileNetV1-28 三个模型的平均准确率分别为 99.35%, 98.71% 和 99.14%。DenseHF-Net 的准确率比 ResNet-18 高 0.64%, 比 MobileNetV1-28 高 0.21%。三个模型的平均敏感度分别达到了 99.08%, 99.09% 和 100.00%。DenseHF-Net 的敏感度比 ResNet-18 低 0.01%, 比 MobileNetV1-28 低 0.92%。三个模型的平均特异性分别测得为 99.75%, 98.10% 和 97.95%。DenseHF-Net 的特异性比 ResNet-18 低 1.65%, 比 MobileNetV1-28 低 1.80%。三个模型的平均 F1 分数分别为 99.42%, 98.59% 和 98.97%。DenseHF-Net 的 F1 分数比 ResNet-18 高 0.83%, 比 MobileNetV1-28 高 0.45%。

表 3-11 多域融合听诊结果

评价指标	DenseHF-Net	ResNet-18	MobileNetV1-28
Acc (average \pm sd, %)	99.35 \pm 0.71	98.71 \pm 1.26	99.14 \pm 0.65
Se (average \pm sd, %)	99.08 \pm 1.22	99.09 \pm 0.92	100.00 \pm 0.00
Sp (average \pm sd, %)	99.75 \pm 0.75	98.10 \pm 2.68	97.95 \pm 1.54
F1 - Score (average \pm sd, %)	99.42 \pm 0.64	98.59 \pm 1.49	98.97 \pm 0.78

3.7 本章小结

本章的工作是针对急性心衰智能快速听诊的算法设计, 工作内容包含: 数据集的建立、心音信号的预处理、轻量级卷积神经网络的搭建、适用于不同临床需求的听诊策略探讨。实现了轻量级心衰听诊模型的开发以及定量评估分析, 具体工作亮点归纳如下:

(1) 数据集部分包括用以模型训练的数据集与用以降噪算法调参的降噪数据集, 与一个用以评估模型泛化能力的公开数据集。

(2) 心音预处理部分包括小波降噪与基于梅尔倒谱系数的特征提取。小波降噪算法, 选取了小波基与分解层数, 提出了一个 $f_{self}(x)$ 阈值函数, 最终信噪比结果为 7.8dB。

(3) 提出了一个 DenseHF-Net 心衰诊断模型, 121 层卷积神经网络架构, 参数数量为 3.82M, 模型的内存访问成本为 130.89M。

(4) 提出了两种听诊策略。二尖瓣单域听诊策略的平均准确率为 93.63%。在多域融合听诊策略中的平均准确率为 99.35%。

本章的诊断模式是短时长听诊的智能算法。二尖瓣单域听诊策略依靠二尖瓣听诊区的 3 秒听诊记录做出心衰诊断，适用于救护车等快速诊断场景。多域融合听诊策略依靠二尖瓣、主动脉瓣、肺动脉瓣三个听诊区各 3 秒的听诊记录做出心衰诊断，适用于病房诊断或者监护场景。

第4章 基于心动周期的心衰听诊模型研究

4.1 引言

本章的工作是基于第三章轻量级心衰听诊模型研究的结果，与第二章可穿戴设备设计相结合，集成心动周期信息使用 DenseHF-Net，以实现针对急性心衰的 15 秒~60 秒的听诊采集与医师复听，适用于急性心衰患者的分流导诊。本章内容包括基于心电的周期分割研究、结合心动周期信息的心衰听诊集成学习，并就所有研究进行比较与讨论。步骤如下：

首先，基于 MIT-BIH 心律失常库（MIT-BIH Arrhythmia Database）^[26]开发心电 R 峰检测算法。评估 R 峰检测精度，并使用检测结果划分心动周期，实现整周期心音信号分段。

然后，对多段整周期心音调用 DenseHF-Net 得到多个诊断结果。设计集成算法，基于多个诊断结果得到心衰最终诊断结果。

最后，讨论本文的必要性和合理性。分别是：时频特征在临床不同阶段的变化；心音听诊对金标准的替代性。

4.2 心动周期分割的必要性

在深度学习诊断模型的研究中，心音的最佳输入长度是一个备受争议的话题。不同的研究和数据集可能会采用不同的长度标准，具体取决于研究的目的、数据集的特点以及算法的需求。


在 PhysioNet 2016 数据集中，包含了 665 个异常心音和 2575 个正常心音，录音的长度范围从 3 秒到 60 秒不等。在心脏诊断预测中，听诊的快速性是非常重要的，因此在一些研究中可能会选择较短的输入长度。Yaseen 数据集则包括了 1000 个异常心音和 200 个正常心音，所有录音的长度标准化为 2 秒。这两个数据集的不同处理方式反映了对心音输入长度的不同看法。

如图 4-1 所示，心音输入长度的选择直接影响包含的心脏事件数量，包括 S1、舒张期、S2 和收缩期。


如图 4-1 (a)所示，1.5 秒的输入理论上可以包含两个舒张期和两个收缩期事件。

如图 4-1 (b)所示，2 秒的输入可以包含至少两个完整的心脏周期。


如图 4-1 (c)所示, 3 秒的输入可以容纳三到四个完整的心脏周期。



(a) 每 1.5 秒切割



(b) 每 2 秒切割



(c) 每 3 秒切割

图 4-1 不同时长听诊的影响

因此, 在设计和选择心音输入长度时, 需要综合考虑研究的目的、数据集的特点以及模型的需求, 以确保能够充分捕捉到关键的心脏事件, 同时保持模型的高效性和实用性。在本文中, 3.5 章的输入长度被设定为 3 秒, 这样可以包含三到四个完整的心脏周期。在 4.4 章, 输入长度与心电的整周期分割信息相结合, 固定为 5 个完整的心动周期, 以更全面地捕捉心音特征。其作用如下:

更好的医学可解释性。心衰患者的每拍心音并不一定都异常, 但一般都包含不同的杂音, 如二尖瓣关闭不全或主动脉瓣关闭不全等等导致的杂音。多段完整

的听诊更符合临床传统听诊流程，即单个听诊区用时约一分钟，仔细分辨心率、节律、强弱、分裂和杂音等特征。而上述特征的分辨都是以第一心音为起点，等待第二心音出现，如此反复。

更好的结果稳健性。假阴性的降低减少了误诊的风险，避免患者可能被漏诊或延误治疗。特别是对于严重的心脏疾病，如心肌梗死或心脏瓣膜病变，假阴性诊断可能导致患者未能及时接受必要的治疗，从而增加了患者的风险和不良后果。

减少频谱泄露。非周期截断处理方式对短时分析影响尤其严重，因此引入心电信息进行时域分段。

4.3 心动周期分割算法设计

使用心电记录分割心动周期，现有研究广泛使用 R 峰作为心动周期检测的关键事件。在 MIT-BIH 数据集上，使用自适应加窗算法检测心动周期边界的准确率为 99.25%。使用改进 U-net 模型检测 QRS 复合波和 R 峰位置的准确率为 99.76%。

本节旨在研究基于心电 R-R 间期提取单周期心音数据。

心电（ECG）记录了心脏在每个心跳周期内的电活动，包括 P 波、QRS 波群和 T 波等。P 波代表心房的去极化和复极化过程，表明心房肌的兴奋传导。QRS 波群代表心室的去极化过程，标志着心室肌的兴奋传导。T 波代表心室的复极化过程，表示心室肌细胞重新极化以准备下一次心跳。P 波代表心房收缩，QRS 波代表心室的收缩，而 T 波代表心室舒张。在心电图上，从一个 P 波的起始点到下一 T 波的终止点代表了一个完整的心动周期。

心脏听诊通常能够听到两个主要的心音，它们分别被称为第一心音（S1）和第二心音（S2）。第一心音通常由心房和心室的瓣膜关闭引起，标志着心脏的收缩期开始。第一心音与第二心音之间是收缩期（Systole）。第二心音通常由主动脉瓣和肺动脉瓣关闭引起，标志着心脏的舒张期开始。第二心音结束后是舒张期。第三心音（S3）和第四心音（S4）是心脏听诊中可能听到的额外心音，对应于心脏的舒张期。第三心音产生于心脏舒张期早期，当心室充盈速度增加时，尤其是在心脏舒张期的早期阶段，这可能表示心室舒张功能减弱或者心室容积增加。第三心音常常是在左心室充盈压力升高时出现，如心力衰竭等情况下。第四心音产生于心房向心室收缩期早期，当心房肌在对抗性充盈时收缩，而心室肌已经变得僵硬和不灵活时。第四心音通常是心室舒张末期的结果，可能是由于高血压、心肌肥厚或缺血等因素引起。

如图 4-2 所示，是心电与心音周期对应关系。听诊中的单个周期并不与心动

周期完全对应。本部分研究旨在提取每个 R 波的时间坐标，由此得到完整的第一心音，收缩期，第二心音，舒张期的完整单个听诊周期。




图 4-2 心电与心音周期对应关系^[61]

4.3.1 心电数据集

MIT-BIH 心律失常库 (MIT-BIH Arrhythmia Database) ^[26] 是本部分研究所使用的数据集。数据集由美国麻省理工学院提供，包含 48 条双通道动态心电信号记录，每一条都超过了 30 分钟，记录来自于心律失常实验室的 47 名受试者。受试者为 25 名年龄在 32 至 89 岁之间的男性和 22 名年龄在 23 至 89 岁之间的女性（201 例和 202 例来自同一男性）。数据采样频率为 360Hz。

MIT-BIH 心律失常数据库每一个数据记录都包含三种文件：“.hea”、“.dat”和“.atr”。其中，.hea 文件为头文件，记录文件名、导联数、采样率、数据点数、数据存储格式、信号增益、ADC 分辨率、患者年龄性别等信息；.dat 文件为数据文件，记录了具体的心电信号，采用 212 格式（按二进制将 2 个信号的数据交替存储，每 3 个字节存储 2 个数据，每个数据占用 12bit）进行存储；.atr 文件为注释文件，记录了心电专家对相应的心电信号的诊断信息。

表 4-1 数据集样本通道与导联信息

文件名	通道一	通道二	文件名	通道一	通道二
100	ML II	V5	201	ML II	V1
101	ML II	V1	202	ML II	V1
102	V5	V2	203	ML II	V1
103	ML II	V2	205	ML II	V1
104	V5	V2	207	ML II	V1
105	ML II	V1	208	ML II	V1
106	ML II	V1	209	ML II	V1
107	ML II	V1	210	ML II	V1
108	ML II	V1	212	ML II	V1
109	ML II	V1	213	ML II	V1
110	ML II	V1	214	ML II	V1
111	ML II	V1	215	ML II	V1
112	ML II	V1	216	ML II	V1
113	ML II	V1	217	ML II	V1
114	V5	ML II	219	ML II	V1
115	ML II	V1	220	ML II	V1
116	ML II	V1	221	ML II	V1
117	ML II	V2	222	ML II	V1
118	ML II	V1	223	ML II	V1
119	ML II	V1	228	ML II	V1
121	ML II	V1	230	ML II	V1
122	ML II	V1	231	ML II	V1
123	ML II	V5	232	ML II	V1
124	ML II	V4	233	ML II	V1
200	ML II	V1	234	ML II	V1

4.3.2 心动周期提取

如图 4-3 所示，心电的分割算法流程包括使用 PhysioNet 提供的封装方法读取 ECG 信号，计算信号处理阈值，基于阈值实现信号均一化，计算 R 峰位置，剔除错误位置，最后得到 R 峰位置。并与数据集标注位置进行比较，得到计算精度。




图 4-3 心动周期分割算法流程图

数据读入使用波形数据库（WFDB）提供的 `wfdb.rdsamp` 方法。大多数 PhysioBank 数据库中的数据和注释都以波形数据库（WFDB）格式存储，其中包含两个标准类别：MIT 格式与 EDF 格式。MIT-BIH 心律失常数据库的数据格式即为 MIT 格式，通过 `wfdb.rdsamp` 进行信号的读取与显示。

阈值的公式如式 4-1 所示。阈值被设置为均值加上三倍标准差。

$$threshold = \mu + 3\sigma \quad (4-1)$$

其中均值为 μ ，如式 4-2 所示。

标准差为 σ ，如式 4-3 所示。

$$\mu = \frac{1}{n} \sum_{i=1}^n X_i \quad (4-2)$$

$$\sigma = \sqrt{\frac{1}{n} \sum_{i=1}^n (X_i - \mu)^2} \quad (4-3)$$

其中 n 是数据量， X_i 是第 i 个数据点。

这种动态阈值的设定方法是一种常见的信号处理技术，常用于检测信号中的异常值或噪声。通过将阈值设置为均值加上几倍的标准差，可以使得阈值随着信号的变化而自适应地调整，从而更好地适应不同情况下信号的波动范围。心电 ECG 一种非平稳、非线性、随机性比较强的微弱生理信号，幅值约为毫伏级，频率在 0.05-100Hz 之间。心电信号的噪声来源包括：基线漂移、肌电干扰、工频干扰等。

R 峰的坐标计算通过 `scipy.signal` 方法的 `find_peaks` 函数实现。传入前一步计算得到的阈值，高于阈值的峰才被认为是 R 峰，从而滤除 P 峰与 T 峰。

排除坐标为零与最末尾的 R 峰，因为心电信号的读入起点与终点可能高于阈值。排除间隔 5ms 以内的 R 峰，可能是被误读成 R 峰的高耸 T 峰。

最后得到所有的 R 峰计算坐标结果，并与数据集标注对比。

4.3.3 心动周期结果分析

如图 4-4 所示，是基于上述算法的心动周期计算结果。实验数据是第 100 号样本的通道一 ML II 导联的前 8 秒数据。本文的 R 峰计算坐标分别是第 0.214 秒、第 1.028 秒、第 1.842 秒、第 2.631 秒、第 3.419 秒、第 4.208 秒、第 5.025 秒、第 5.681 秒、第 6.675 秒、第 7.517 秒。数据集标注 R 峰实际坐标分别是第 0.214 秒、第 1.028 秒、第 1.839 秒、第 2.628 秒、第 3.419 秒、第 4.208 秒、第 5.025 秒、第 5.678 秒、第 6.672 秒、第 7.517 秒。小数点后保留三位有效数字，前 8 秒的分割结果吻合。




图 4-4 MIT-BIH 心律失常库 ‘100’ 样本前 8 秒的分割结果

第 100 号样本时长 1805.6 秒，标记 R 峰数量为 2274 个，本文的计算数量为 2277 个。平均误差为 1.616×10^{-3} 秒，平均方差为 2.128×10^{-5} 平方秒。平均误差计算公式如式 4-4 所示。平均方差如式 4-5 所示。

$$ME = \frac{1}{n} \sum_{i=1}^n (A_i - B_i) \quad (4-4)$$

$$Var = \frac{1}{n} \sum_{i=1}^n (A_i - B_i)^2 \quad (4-5)$$

其中 n 是数据量， A_i 是第 i 个计算预测值， B_i 是第 i 个真实值。

4.4 多心动周期的心衰听诊集成学习

4.4.1 实验数据集

本文使用了 2.5.1 章节中采集的数据，于同一被试者共采集六次，每次一分钟。每次同步采集心电与心音数据，采集设备使用第二章设计的可穿戴设备。心音采集的选型是艾医吉昌 ETZ-1 型电子听诊器，采集部位是二尖瓣听诊区。心电采集芯片的选型是 AD8232，采集部位是 V1、V4、LL。

六分钟的同步记录，每 5 个心动周期作为一例，经过数据重叠增殖后得到 2700 例。

4.4.2 模型调用与集成算法设计

如图 4-5 所示，结合心动周期的心衰听诊集成学习流程包括：采集并读取同步心音与心电记录；心音整周期分割；使用 DenseHF-Net 得到多个诊断结果；对子结果进行集成计算并得出最终结果。步骤如下：

首先，读取心音与心电数据。使用 librosa.load 函数读取心音记录。使用 pandas.read_csv 函数读取心电数据。

然后，计算心音的周期坐标。调用 4.2.2 章的心动周期分割算法设计，计算心电 R 峰位置，得到多个心音周期。

接着，基于深度学习模型计算心衰与否。调用 3.3 章的预处理算法，对多段心音进行预处理与特征提取。调用 3.5 章的 DenseHF-Net 模型进行心衰诊断，得到多个心衰与否的结果。如式 4-6 所示，用于计算单个片段的诊断结果。 a_i 代表 DenseHF-Net 最后一层 1×2 线性层的输出。Result_i 代表单个周期的计算结果，计算结果为 0 代表健康，计算结果为 1 代表心衰。

$$\begin{aligned} Result_i &= \max_{a_i} Softmax(a_i) \\ &= \max_{a_i} \frac{\exp(a_i)}{\sum_{i=1}^2 \exp(a_i)} \end{aligned} \quad (4-6)$$

再次，对多个诊断结果进行集成计算。如式 4-7 所示，为了降低假阴性率，对多个结果进行集成或运算。 n 代表周期数，本文中设置为 5，使用 5 个心动周期得到一个集成结果。

$$Output = Result_1 \vee Result_2 \vee \dots \vee Result_n \quad (4-7)$$

最后得到一段 10 秒以上听诊的结果。

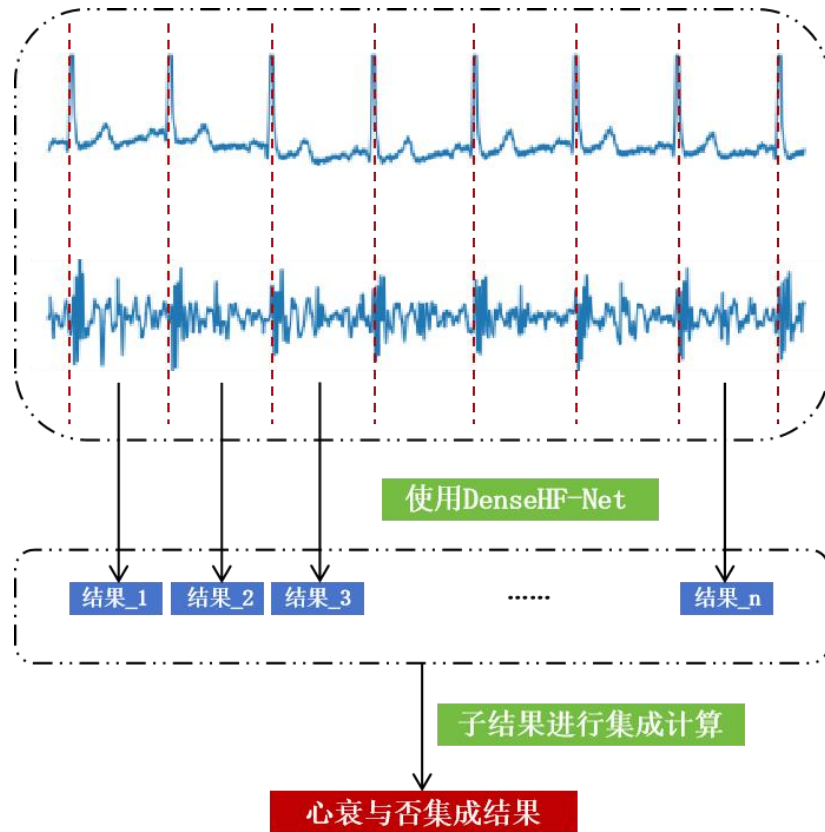


图 4-5 结合心动周期信息的集成计算流程

4.4.3 实验结果分析

如表 4-2 所示，是结合心电的集成诊断结果，多周期集成诊断的准确率为 94.41%。3.5 章的二尖瓣单域听诊平均准确率为 93.63%，每次输入音频长度为 10 秒~15 秒，且无须关注是否整周期。本部分的研究较之 3.5 章准确率提高了 0.78%，敏感性提高了 1.83%，特异性降低了 0.95%，总体 F1 分数提高了 0.38%。

本部分的研究更关注敏感性指标，集成整周期信息的必要性在于降低漏诊率。改进听诊策略使其拥有更低的假阴性率，对于心衰快诊更有意义。

提高敏感度可以及时干预和治疗，能够显著降低死亡率与再次入院率。重视敏感度可以确保尽可能多的患者能够被诊断出来，及早接受治疗，从而减少不良后果的发生。

提高敏感度可以进一步筛查潜在的非典型症状患者。急性心衰的临床表现可

能不典型，包括呼吸困难、心悸、乏力等，这些症状也可能与其它疾病相似。

表 4-2 结合心电的集成听诊与集成之前的比较

听诊策略	Acc (%)	Se (%)	Sp (%)	F1 – Score (%)
二尖瓣单域听诊	93.63	94.28	92.95	93.57
结合心动周期的集成听诊	94.41	96.11	92.00	93.95

综上，结合心动周期信息的心音-心电双模态诊断方法实现了急性心衰的快速诊断，使用诊断手套设备放置正确的采集位置可以在 1 分钟内得到诊断结果。既保留了仅凭短时长心音诊断模式的便捷化优势，又能降低漏诊率。

4.5 系统测试与讨论

4.5.1 临床数据的频谱分析

本文的深度学习模型输入特征是时频特征，本章的讨论内容是临床不同阶段的听诊在频谱上的体现，以及听诊对生理信息的反馈。

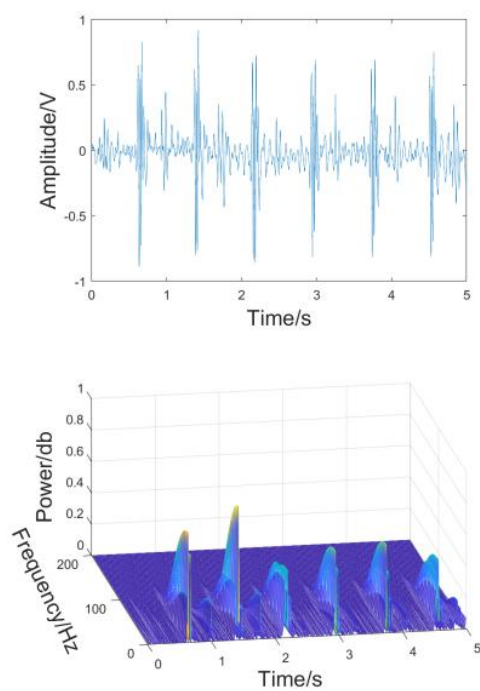
心音携带与心脏泵血能力相关的重要生理信息。最主要的听诊区域是二尖瓣区域，位于最强心尖搏动点处。使用短时傅里叶变换分析心音的时频特征，如图 4-6 (a)所示，是二尖瓣听诊区采集的一段 5 秒的记录。稳定的 S1 振幅主要集中在 100 Hz 的频率范围内。

主动脉瓣听诊区位于右锁骨中线的第二肋间隙，相对于二尖瓣距离心脏较远。如图 4-6 (b) 所示，主动脉瓣听诊区受到肺音影响而嘈杂，距心脏远从而 S1、S2 振幅低于二尖瓣区。

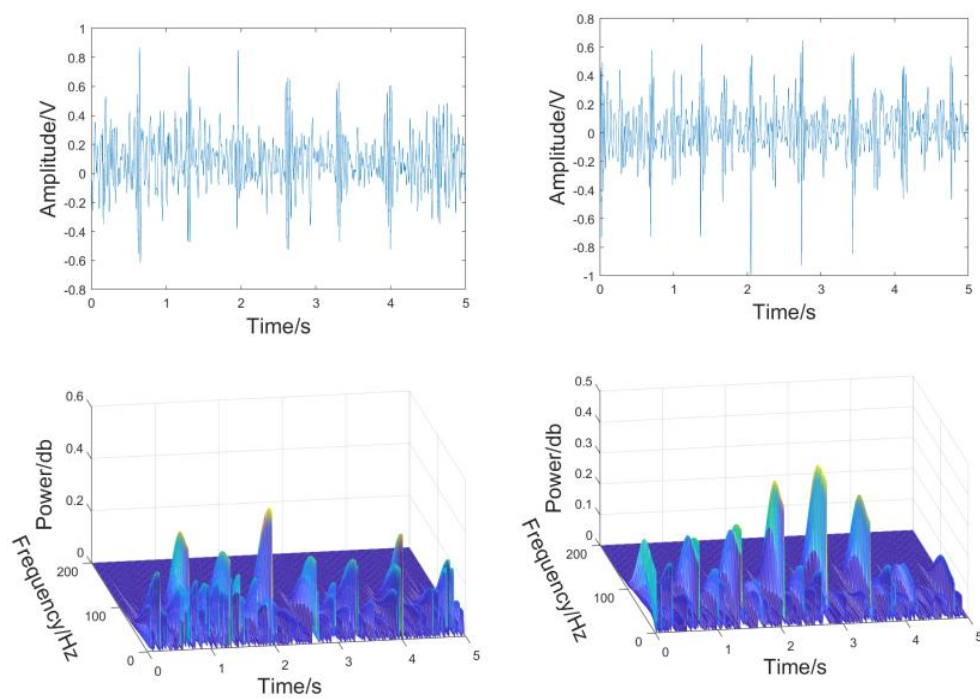
肺动脉瓣位于左锁骨中线的第二肋间隙，其信号特征介于二尖瓣和主动脉瓣之间。如图 4-6 (c)所示，肺动脉瓣听诊区的记录同样收到肺音的强烈，但是心音 S1、S2 振幅比主动脉瓣大。

本文涉及从同一患者处收集二尖瓣心音，在急救前后的情况如图 4-7 (a)和图 4-7 (b)所示。与健康受试者相比，患者 S1 的振幅不稳定，并伴有嘈杂的肺音。在急救的两天后，二尖瓣区域的听诊大幅改善。心音周期变得更清晰，S1 的能量振幅更加突出。

综上，本文的采集设备可以自动滤除背景噪音，得到被试者典型生理信息。设计了契合心脏听诊模式的频响修正，更加专注于心脏听诊，减少了肺音干扰，更适用于急性心衰的快速诊断。



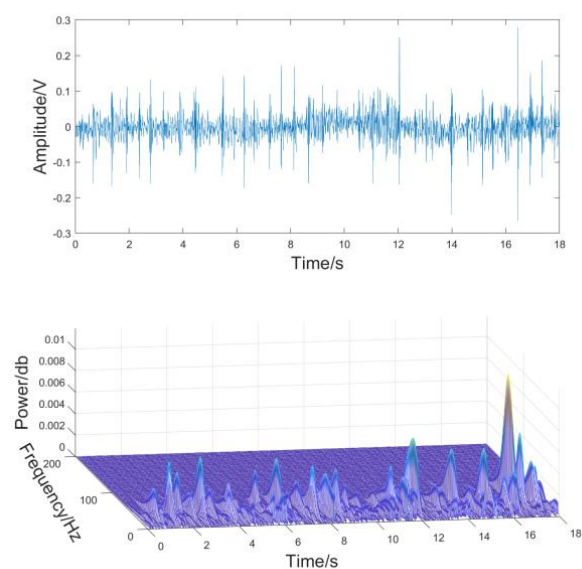
(a) 二尖瓣听诊区



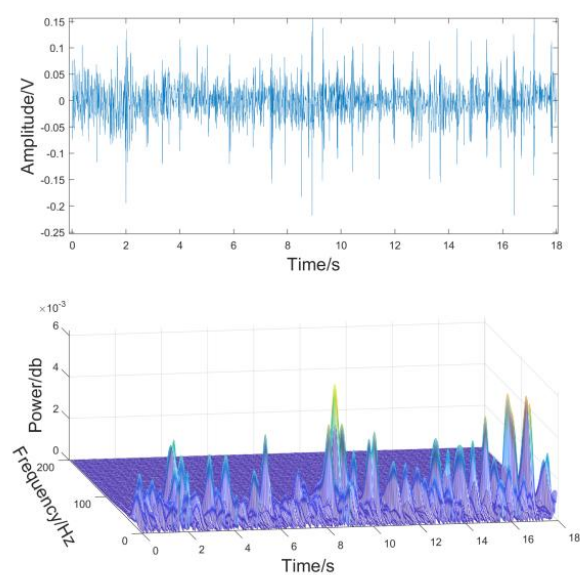
(b) 主动脉瓣听诊区

(c) 肺动脉瓣听诊区

图 4-6 不同听诊部位频谱特征



(a) 急救前



(b) 急救后

图 4-7 急救前后频谱特征

4.5.2 与心衰诊断金标准的比较

欧洲心脏病学会将心衰分期为四期^[11]。

阶段 A：高风险，但没有结构性心脏疾病或症状。

阶段 B：结构性心脏疾病，但没有症状。

阶段 C：结构性心脏疾病，且有历史或当前的症状。

阶段 D：顽固性心衰，需要特殊治疗或终末关怀。

阶段 C、阶段 D 的患者往往有明确的心脏病史。针对阶段 A、阶段 B 的心衰患者，欧洲心脏病学会^[11]给出的心衰诊断金标准包括：患者症状、生理参数、影像学检查、生化检查等。患者症状包括：呼吸困难、乏力、体力活动受限、水肿、心悸等。生理参数检查包括：心率、呼吸频率、血压、颈静脉充盈度、心音、心肺听诊、水肿等。影像学检查包括：超声心动图、X 线胸片等，用于评估心脏结构和功能是否异常。生化检查包括：BNP、NT-proBNP 水平，用于辅助心衰的诊断和评估。

本文评估比较了听诊对其它诊断金标准的替代性，已有研究如表 4-3 所示。Khade 等人^[79]和 Rao 等人^[80]基于生理参数或药物记录预测了心力衰竭的发病率。生理参数通常包括患者的心率、血压、心排量、肾功能等指标，这些参数可以通过医学检查或监测设备来获取。药物记录则指的是患者接受的药物治疗信息，包括药物种类、剂量、使用频率等。Khade 等人^[79]和 Rao 等人^[80]通过分析这些生理参数和药物记录，研究人员可以探索它们与心力衰竭发病率之间的关联，从而建立预测模型。Khade 等人^[79]基于支持向量机算法用于心力衰竭类型的检测，并获得了 84% 的准确率。输入参数包括每分钟平均心率 (Avg heart beat permin)、每天心悸次数 (Palpitations perday)、胆固醇水平 (Cholesterol)、体重指数 (BMI)、年龄 (age)、性别 (sex)、家族病史 (Family history)、过去 5 年是否吸烟 (Smoker last 5yrs) 和每周运动分钟数 (Exercise min perweek)。然后基于卷积神经网络预测心力衰竭的严重程度，准确率为 88.30%。Rao 等人^[80]使用的金标准包括：既有病史、出生年月、用药记录。既有病史包括：高血压、心房颤动、心肌梗塞、I 型糖尿病、II 型糖尿病、缺血性中风等。用药记录包括：抗高血压药、地高辛、糖尿病药物等。Rao 等人^[80]基于 100071 名患者的上述数据，使用 Transformer 的风险模型预测 6 个月内的心力衰竭发病概率。在 5 折交叉验证中，模型达到了 0.93 的接收器运算曲线下面积 (Area under the receiver operator curve) 和 0.69 的精度-召回曲线下面积 (Area under the precision-recall curve)^[80]。与 Khade 等人^[79]和 Rao 等人^[80]相比，本文实现了相仿的诊断准确率。和 Khade 等人^[79]使用的心率、血压、心排量、肾功能等生理参数，听诊作为心衰诊断金标准的优势在于：(1) 心衰诊断算法能够在 60 秒以内实现快速诊断；(2) 心衰阶段 A 的患者没有结构性心脏疾病或症状，过往用药记录可能不全。听诊诊断不依赖过往用药记录。与 Rao 等人^[80]的 6 个月内的心力衰竭发病预测研究相比，本文使用的听诊的优势在于：(1) 听诊能够提供即时诊断结果；(2) 处于失代偿期的心衰患者不一定能够提供用药记录，听诊较之具有更好的实现性。

Acharya 等人^[81]和 Matsumoto 等人^[82]考察了使用心电图或 X 射线图像诊断心力衰竭的潜力。在 Acharya 等人^[81]的研究中，心电信号被直接投入一个 11 层的

卷积神经网络模型。识别准确率为 98.97%，特异性为 99.01%，敏感性为 98.87%。在 Matsumoto 等人^[82]的研究中，使用了美国国立卫生研究院发布的标记数据库中的 952 张胸部 X 光图像^[83]。两位心脏病专家验证并重新标记了总共 260 个“正常”图像和 378 个“心力衰竭”图像，其余图像因标记错误而被丢弃。使用数据增强和迁移学习，在诊断心力衰竭方面获得了 82% 的准确率。与 Acharya 等人^[81]和 Matsumoto 等人^[82]相比，听诊的优势在于：（1）较之心电图监测和 X 光检测，听诊拥有更快的诊断速度、更小的设备尺寸，并且更适用于救护车设置。（2）心电图监测提供客观的心脏电活动信息，可以准确地记录心脏节律和传导系统的功能状态。听诊较之心电的优势在于能够展现心音强度和心音特征，直观反应心脏的物理结构与病理信息^[84-87]。

表 4-3 基于金标准的心衰检测研究

作者	数据集	检测对象
本文	心衰听诊数据集	急性心衰
Khade ^[79]	用药与生理参数	慢性心衰
Rao ^[80]	用药记录、年龄、病史	慢性心衰
Acharya ^[81]	心电 ECG 记录	急性心衰
Matsumoto ^[82]	X 光检测结果	急性心衰

表 4-4 基于心音的诊断研究

作者	特征提取	算法模型	数据集	Acc (%)
本文	梅尔倒谱系数频谱	DenseHF-Net	自采听诊数据集	94.41
Vepa ^[63]	短时傅里叶变换，离散小波特征	kNN, MLP, SVM	自采听诊数据集	95.2
Wu ^[64]	梅尔倒谱系数频谱	HMM	自采听诊数据集	95.08
Rubin ^[65]	梅尔倒谱系数频谱	CNN	PhysioNet 2016	95.2
Arora ^[66]	短时傅里叶变换	CNN	PhysioNet 2016	89.04
Li ^[67]	短时傅里叶变换	CNN	PhysioNet 2016	85
Shuvo ^[68]	时不变特征	CNN	Yaseen	99.6

已有的心音诊断算法^[63-68]工作包含特征提取、模型搭建两部分，如表 4-4 所示。在 Vepa^[63]、Arora^[66]、Li^[67]等人的研究中，特征提取使用了短时傅里叶变换。在 Wu^[64]、Rubin^[65]等人的研究中，特征提取使用了梅尔倒谱系数频谱。Rubin^[65]、Arora^[66]、Li^[67]、Shuvo^[68]等人的研究中，算法模型使用了浅层卷积神经网络。

针对急性心衰听诊的智能化、快速化需求,本文提出了一套信号处理、特征提取、模式识别方案,并结合数据完成了验证。

在预处理方面,本文借鉴了 Vepa^[63]使用的小波变换,沿用了 Wu^[64]与 Rubin^[65]使用的梅尔倒谱系数特征。

在诊断准确率方面,本文的单域诊断结果与表 4-4 中的其它结果相近,为 94.41%。考虑到自采听诊数据集数据量多于公开数据集,且心衰听诊识别难度较大,本文在大幅缩短数据量减少计算量条件下取得了与一流水平相当的准确率,同时在三甲医院临床测试过程中得到一线医生普遍认可,已经投稿 SCI 二区杂志并申请发明专利。

本文的模型参数量仅为 3.82M,能够在计算资源受限环境中高效运行。与表 4-4 中模型比较,本文的模型是部署移动设备上的理想选择。算法优化后已经应用到快检产品,目前正由合作公司申请二类医疗器械注册取证。

本文的诊断便捷性优势明显,仅使用了 5 个心动周期,可以将诊断时长压缩到 1 分钟以内,更适用于急性心衰的导诊分流场景。而 Rubin^[65]、Arora^[66]、Li^[67]等人使用了完整的心音记录,输入长度甚至达到 5 分钟。

考虑到错误诊断案例集中于二尖瓣返流这一病因,表明了模型对二尖瓣返流造成的急性心衰病例仍有改进空间,这可能是由于样本数据不足造成,也可能是听诊部位单一造成。可以考虑后续增加相应病例数据,或引入多听诊区域融合决策,进行针对性强化学习,以期改善效果。

4.6 本章小结

本章使用了第二章设计的硬件设备与第三章的算法模型。本章的工作意义在于:

(1) 对应不同临床需求。第三章是仅依靠每个听诊区 3 秒的短时心衰听诊,对应救护车初诊、病房急诊场景。本章实现了二尖瓣区域的 15 秒以上的长时间听诊,对应数据采集、医师复听需求。诊断准确率为 94.41%,较之 3.5 章未引入心电的算法,敏感性提高了 1.83%,特异性降低了 0.95%,更加注重减少心衰急诊中假阴性案例。

(2) 完善医学可解释性。基于心电辅助分割心音,实现了多个心动周期的心衰诊断,有更好医学解释性。

(3) 降低移动端计算量。实现心电与心音的同步采集与上传,调用云端 GPU 资源,以较低的移动端功耗实现快速诊断。

本章的具体工作包括:算法设计、系统测试与讨论。算法设计工作包括:基

于心电的心动周期分割算法、结合心动周期的心衰听诊集成学习，完成临床测试并讨论了上述研究的合理性与必要性。

首先，完成了基于心电信号的心动周期分割。算法研究选取使用了 MIT-BIH 心律失常库。基于自适应阈值进行数值均一化，然后寻峰计算得到 R 峰坐标。基于测试数据集的平均误差为 1.616×10^{-3} 秒，平均方差为 2.128×10^{-5} 平方秒。

然后，完成了基于心动周期信息的心衰听诊集成学习。每 5 个心动周期给出一次集成计算结果，准确率为 94.41%。

最后，讨论了本文的必要性与合理性。不同听诊区的时频特征反应了不同的被试者生理特征，急救后的患者的心音较之急救前更稳健与清晰。过短的听诊时长难以囊括所有典型病理信息，从而导致漏诊。结合心动周期信息的听诊算法拥有更好的临床解释性与稳健性。与生化指标、X 光等临床金标准比较，本文方案更加低廉与快速。较之过往的心音处理算法，本文更加聚焦与急性心衰急救场景的特定需求。

第5章 总结与展望

5.1 总结

心血管疾病是全球死亡和残疾的主要原因。心衰是心血管疾病发展的末期阶段，其特征是心脏的收缩、舒展功能失调。急性心衰是老年人群急诊入院的主要原因。急性心衰的急救程序包括救护车响应、入院-球囊扩张时间、急诊和病房转移。缩短救护车响应与入院-球囊扩张时间，甚至在救护车响应期间完成初步诊断，都可以显著提高患者的生存率。听诊在欧洲心脏病学会急救指南^[1]中被列为金标准之一，但目前仍然缺少智能化算法研究，也缺乏算法研究需要的数据集和硬件设备。本文的急性心衰快速诊断关键技术研究天津市第四中心医院合作展开，获得天津市第四中心医院医学伦理委员会的批准（批准号：No. 2022-T050）。

本文以开发急性心衰快速、智能的诊断方法为目标，开发了一系列硬件、软件、算法。开发了一体化可穿戴手套设备，并设计了适配的频响曲线修正算法和采集界面软件。开发了轻量级心音单模态诊断模型，搜集建立了高质量心衰听诊记录数据集，设计了心音处理算法，并提出了两种听诊策略。提出了基于心动周期信息的心衰听诊诊断模型，适用于急性心衰导诊分流场景。本文的具体工作如下：

（1）设计心电、心音同步采集可穿戴设备。选取 AD8232 作为心电采集芯片，采集 V1、V4、LL 三个导联位置的心电，配置电路增益为 1100。选择艾医吉昌 ETZ-1 型作为心音拾取探头，采集二尖瓣听诊区域心音。设计了与采集硬件相适配的前处理软件。设计频响曲线修正，将 50Hz~500Hz 频段的增益调整到 20dB 左右，符合相关行业标准。设计陷波滤波器，消除 50Hz 倍频干扰。使用 STM32F767IGT6 作为主控芯片，实现了心电、心音信号的同步采集。基于 Qt5 框架绘制上位机采集软件界面，实现了心音、心电信号的同步收集，并绘制被试者信息录入界面。

（2）建立高质量数据集。与天津市第四中心医院合作自建了三个数据集：二尖瓣听诊数据集、多域融合听诊数据集、心音降噪数据集。二尖瓣听诊数据集包括 1620 例健康病例和 1379 例心力衰竭病例。多域融合听诊数据集包括 540 例健康病例和 389 例心力衰竭病例。心音降噪数据集包含 26 组降噪前后的对比数据。

（3）设计心音预处理算法。完成了适用于短时心音信号的小波降噪算法，

比较选取了小波基、分解层数、分解阈值，设计了最佳效果的自适应阈值函数 $f_{self}(x)$ ，实现了 7.8dB 信噪比的降噪效果。完成了基于梅尔频率倒谱系数的特征提取，有效提取心音时频特征图谱。

(4) 设计了心音单模态诊断模型 DenseHF-Net，121 层卷积神经网络架构，参数量为 3.82M，内存访问成本为 130.89M。设计了二尖瓣单域听诊策略，适用于救护车等快速诊断场景，平均准确率为 93.63%。设计了多域融合听诊策略，适用于病房诊断或者监护场景，平均准确率为 99.35%。

(5) 设计了心电-心音双模态集成诊断模型，更适用于急性心衰的导诊分流场景，并且保留了 DenseHF-Net 的便捷化、轻量化特点。相较于目前临床动辄 20 分钟以上的生化检测和超声心动图检查，本文有希望将诊断时长限制在 1 分钟以内。完成了基于心电的心动周期信息提取，设计了自适应阈值函数检测 R 峰位置，在 MIT-BIH 心律失常库上的测试平均误差为 1.616×10^{-3} 秒。完成了基于心动周期信息的听诊集成诊断算法，使用 DenseHF-Net 得到多个诊断结果后集成分析得到最终的急性心衰快速诊断结果，平均准确率为 94.41%。

5.2 展望

本文研究成果可以为急性心衰临床诊断提供辅助决策支持，但仍然存在许多地方可以进一步研究，包括：

(1) 硬件设备配合公司推进商业化进程，完成二类医疗器械产品注册。满足相关法规标准，进行必要的测试和验证，并确保设备安全性和性能稳定性。

(2) 完成更多模态的急性心衰诊断研究。建立一个涵盖多种模态数据的心衰患者数据集，不仅包括心电图数据，还包括影像学数据（如超声心动图、核磁共振图像等）和临床数据（如病历记录、生理参数等），提供更全面的患者病理信息，为后续研究提供数据支持。

(3) 算法模型进一步的落地部署。训练样本的性别和年龄分布更加均衡。将模型嵌入到现有医疗设备或系统中，监测实时性能并进行相应优化。完善用户界面设计，确保算法模型为临床医生所用，更好地满足临床需求，实现更广泛的应用与推广。

参考文献

- [1] Update A H A S. Heart disease and stroke statistics—2020 update: a report from the American Heart Association[J]. Circulation, 2020, 141(9): e139-e596.
- [2] Roth G A, Mensah G A, Johnson C O, et al. Global burden of cardiovascular diseases and risk factors, 1990 – 2019: update from the GBD 2019 study[J]. Journal of the American college of cardiology, 2020, 76(25): 2982-3021.
- [3] Mensah G A, Roth G A, Fuster V. The global burden of cardiovascular diseases and risk factors: 2020 and beyond[J]. Journal of the American College of Cardiology, 2019, 74(20): 2529-2532.
- [4] Boorsma E M, Ter Maaten J M, Damman K, et al. Congestion in heart failure: a contemporary look at physiology, diagnosis and treatment[J]. Nature reviews cardiology, 2020, 17(10): 641-655.
- [5] Sinnenberg L, Givertz M M. Acute heart failure[J]. Trends in cardiovascular medicine, 2020, 30(2): 104-112.
- [6] Arrigo M, Jessup M, Mullens W, et al. Acute heart failure[J]. Nature Reviews Disease Primers, 2020, 6(1): 16.
- [7] Chapman B, DeVore A D, Mentz R J, et al. Clinical profiles in acute heart failure: an urgent need for a new approach[J]. ESC heart failure, 2019, 6(3): 464-474.
- [8] Victor S M, Gnanaraj A, Vijayakumar S, et al. Door-to-balloon: where do we lose time? Single centre experience in India[J]. indian heart journal, 2012, 64(6): 582-587.
- [9] 王潇,潘一龙,常程,等.总缺血时间与入院-球囊扩张时间对急性心肌梗死病人主要心脏不良事件发生率的影响[J].中西医结合心脑血管病杂志,2023,21(10):1877-1880.
- [10] Fan Z, Zhang F. Effects of an emergency nursing pathway on the complications and clinical prognosis of patients with acute myocardial infarction[J]. Int J Clin Exp Med, 2021, 14(1): 661-668.
- [11] Task Force Members, Niemenen M S, et al. Executive summary of the guidelines on the diagnosis and treatment of acute heart failure: the Task Force on Acute Heart Failure of the European Society of Cardiology[J]. European heart journal, 2005, 26(4): 384-416.
- [12] Lewis R A, Durrington C, Condliffe R, et al. BNP/NT-proBNP in pulmonary arterial hypertension: time for point-of-care testing?[J]. European Respiratory Review, 2020, 29(156).

- [13]Menon P, Kapoor P M, Choudhury M. Echocardiography for Left Ventricular Assist Device Patients[J]. Journal of Cardiac Critical Care TSS, 2022, 6(02): 155-161.
- [14]Johnston M, Collins S P, Storrow A B. The third heart sound for diagnosis of acute heart failure[J]. Current Heart Failure Reports, 2007, 4(3): 164-169.
- [15]Wynne J. The clinical meaning of the third heart sound[J]. The American Journal of Medicine, 2001, 111(2): 157-158.
- [16]郑伊能.基于心音的慢性心力衰竭分期诊断方法研究[D].重庆大学,2017.
- [17]陈尧.心音心电信号处理的神经网络方法[D].四川大学,2021.
- [18]李海霞.面向冠心病早期无损诊断的 MEMS 电子听诊器与心音特征提取研究 [D].中北大学,2020.
- [19]付俊义.基于深度学习的慢性阻塞性肺疾病的肺音诊断[D].中国医科大学,2023.
- [20]徐尚成.基于小波与自适应滤波的心音降噪算法研究和便携式听诊器设计[D].华中科技大学,2022.
- [21]Lee S Y, Su P H, Hsieh Y T, et al. Intelligent Stethoscope System and Diagnosis Platform With Synchronized Heart Sound and Electrocardiogram Signals[J]. IEEE Access, 2023.
- [22]Fernando T, Ghaemmaghani H, Denman S, et al. Heart sound segmentation using bidirectional LSTMs with attention[J]. IEEE journal of biomedical and health informatics, 2019, 24(6): 1601-1609.
- [23]Huang G, Liu Z, Van Der Maaten L, et al. Densely connected convolutional networks[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 4700-4708.
- [24]Niroshana S M I, Kuroda S, Tanaka K, et al. Beat-wise segmentation of electrocardiogram using adaptive windowing and deep neural network[J]. Scientific Reports, 2023, 13(1): 11039.
- [25]Peng X, Zhu H, Zhou X, et al. ECG signals segmentation using deep spatiotemporal feature fusion U-Net for QRS complexes and R-peak detection[J]. IEEE Transactions on Instrumentation and Measurement, 2023, 72: 1-12.
- [26]Moody G B, Mark R G. The impact of the MIT-BIH arrhythmia database[J]. IEEE engineering in medicine and biology magazine, 2001, 20(3): 45-50.
- [27]Ghosh S K, Nagarajan P R, Tripathy R K. Heart sound data acquisition and preprocessing techniques: A review[J]. Handbook of research on advancements of artificial intelligence in healthcare engineering, 2020: 244-264.
- [28]Milani M G M, Abas P E, De Silva L C. A critical review of heart sound signal segmentation algorithms[J]. Smart Health, 2022, 24: 100283.

- [29] Vavrinsky E, Subjak J, Donoval M, et al. Application of modern multi-sensor holter in diagnosis and treatment[J]. *Sensors*, 2020, 20(9): 2663.
- [30] Galli A, Ambrosini F, Lombardi F. Holter monitoring and loop recorders: from research to clinical practice[J]. *Arrhythmia & electrophysiology review*, 2016, 5(2): 136.
- [31] 刘红夺儿.基于动态心电图（Holter）数据的充血性心力衰竭患者心率变异性分析[D].北京协和医学院,2016.
- [32] 邓承豪.24 小时动态心电指标对射血分数减低的心力衰竭左室射血分数改善的影响[D].安徽医科大学,2023.
- [33] 涂岳文.Holter 系统中运动伪差自动识别的关键技术及算法研究[D].浙江大学,2013.
- [34] 李金桦.基于移动物联网的动态心电实时监测、管理和服务系统[D].浙江大学,2016.
- [35] 李婷.动态心电信号质量评估及干扰分析研究[D].东南大学,2017.
- [36] Gibson C M, Ciaglo L N, Southard M C, et al. Diagnostic and prognostic value of ambulatory ECG (Holter) monitoring in patients with coronary heart disease: a review[J]. *Journal of thrombosis and thrombolysis*, 2007, 23: 135-145.
- [37] Cygankiewicz I, Zaręba W, et al. Prognostic value of Holter monitoring in congestive heart failure[J]. *Cardiology journal*, 2008, 15(4): 313-323.
- [38] Patel V N, Pierce B R, Bodapati R K, et al. Association of holter-derived heart rate variability parameters with the development of congestive heart failure in the cardiovascular health study[J]. *JACC: Heart failure*, 2017, 5(6): 423-431.
- [39] Musialik-Łydka A, Średniawa B, Pasyk S. Heart rate variability in heart failure[J]. *Polish Heart Journal (Kardiologia Polska)*, 2003, 58(1): 14-16.
- [40] Holter monitor ,Mayo Clinic Press[EB/OL]. [2024-04-26]. <https://www.mayoclinic.org/tests-procedures/holter-monitor/about/pac-20385039>
- [41] Raja J M, Elsagr C, Roman S, et al. Apple watch, wearables, and heart rhythm: where do we stand?[J]. *Annals of translational medicine*, 2019, 7(17).
- [42] Hsiao K L. What drives smartwatch adoption intention? Comparing Apple and non-Apple watches[J]. *Library Hi Tech*, 2017, 35(1): 186-206.
- [43] Khushhal A, Nichols S, Evans W, et al. Validity and reliability of the Apple Watch for measuring heart rate during exercise[J]. *Sports medicine international open*, 2017, 1(06): E206-E211.
- [44] DeVore A D, Wosik J, Hernandez A F. The future of wearables in heart failure patients[J]. *JACC: Heart failure*, 2019, 7(11): 922-932.
- [45] Singhal A, Cowie M R. The role of wearables in heart failure[J]. *Current heart failure reports*, 2020, 17: 125-132.

- [46]Prasad A S, Kavanashree N. ECG monitoring system using AD8232 sensor[C]//2019 International Conference on Communication and Electronics Systems (ICCES). IEEE, 2019: 976-980.
- [47]Oliynik V. On potential effectiveness of integration of 3M Littmann 3200 electronic stethoscopes into the third-party diagnostic systems with auscultation signal processing[C]//2015 IEEE 35th International Conference on Electronics and Nanotechnology (ELNANO). IEEE, 2015: 417-421.
- [48]Khan S I, Ahmed V, Jawarkar N P. Application of signal processing techniques for preliminary detection of adventitious lung sounds in paediatric population using electronic stethoscope[C]//2017 International Conference on Big Data Analytics and Computational Intelligence (ICBDAC). IEEE, 2017: 335-338.
- [49]Naseri H, Homaeinezhad M R, Pourkhajeh H. Noise/spike detection in phonocardiogram signal as a cyclic random process with non-stationary period interval[J]. Computers in biology and medicine, 2013, 43(9): 1205-1213.
- [50]Kalinauskienė E, Razvadauskas H, Morse D J, et al. A comparison of electronic and traditional stethoscopes in the heart auscultation of obese patients[J]. Medicina, 2019, 55(4): 94.
- [51]Blass K A, Schober K E, Bonagura J D, et al. Clinical evaluation of the 3M Littmann Electronic Stethoscope Model 3200 in 150 cats[J]. Journal of feline medicine and surgery, 2013, 15(10): 893-900.
- [52]Arjoun Y, Nguyen T N, Doroshov R W, et al. Technical characterisation of digital stethoscopes: towards scalable artificial intelligence-based auscultation[J]. Journal of Medical Engineering & Technology, 2023, 47(3): 165-178.
- [53]Lin Y J, Chuang C W, Yen C Y, et al. An intelligent stethoscope with ECG and heart sound synchronous display[C]//2019 IEEE international symposium on circuits and systems (ISCAS). IEEE, 2019: 1-4.
- [54]Behere S, Baffa J M, Penfil S, et al. Real-world evaluation of the Eko electronic teleauscultation system[J]. Pediatric cardiology, 2019, 40: 154-160.
- [55]Akella R, Bollavaram K, Brown M T. A Cost-effective, Patient-facing Electronic Stethoscope For Telemedical Cardiac Auscultation[J]. Journal of Cardiac Failure, 2023, 29(4): 595.
- [56]Thiyagaraja S R, Dantu R, Shrestha P L, et al. A novel heart-mobile interface for detection and classification of heart sounds[J]. Biomedical Signal Processing and Control, 2018, 45: 313-324.
- [57]李凤.便携式心音检测系统的研究与开发[D].吉林大学,2022.
- [58]苗佳良.可穿戴手套式心电信号采集方案研究及实现[D].天津工业大学,2022.
- [59]向梦辉.便携式心音信号采集仪器设计及分类算法研究[D].中北大学,2023.
- [60]王朔彤.心音心电一体化采集系统设计及实现[D].中北大学,2023.

- [61] Clifford G D, Liu C, Moody B, et al. Classification of normal/abnormal heart sound recordings: The PhysioNet/Computing in Cardiology Challenge 2016[C]//2016 Computing in cardiology conference (CinC). IEEE, 2016: 609-612.
- [62] Yaseen, Son G Y, Kwon S. Classification of heart sound signal using multiple features[J]. Applied Sciences, 2018, 8(12): 2344.
- [63] Vepa J. Classification of heart murmurs using cepstral features and support vector machines[C]//2009 Annual International Conference of the IEEE Engineering in Medicine and Biology Society. IEEE, 2009: 2539-2542.
- [64] Wu H, Kim S, Bae K. Hidden Markov model with heart sound signals for identification of heart diseases[C]//Proceedings of 20th International Congress on Acoustics (ICA), Sydney, Australia. 2010: 23-27.
- [65] Rubin J, Abreu R, Ganguli A, et al. Classifying heart sound recordings using deep convolutional neural networks and mel-frequency cepstral coefficients[C]//2016 Computing in cardiology conference (CinC). IEEE, 2016: 813-816.
- [66] Arora V, Verma K, Leekha R S, et al. Transfer Learning Model to Indicate Heart Health Status Using Phonocardiogram[J]. Computers, Materials & Continua, 2021, 69(3).
- [67] Li T, Yin Y, Ma K, et al. Lightweight end-to-end neural network model for automatic heart sound classification[J]. Information, 2021, 12(2): 54.
- [68] Shuvo S B, Ali S N, Swapnil S I, et al. CardioXNet: A novel lightweight deep learning framework for cardiovascular disease classification using heart sound recordings[J]. iee access, 2021, 9: 36955-36967.
- [69] Khunti K. Accurate interpretation of the 12-lead ECG electrode placement: A systematic review[J]. Health Education Journal, 2014, 73(5): 610-623.
- [70] van Dam P M, Boonstra M, Locati E T, et al. The relation of 12 lead ECG to the cardiac anatomy: the normal CineECG[J]. Journal of Electrocardiology, 2021, 69: 67-74.
- [71] Fu L, Lu B, Nie B, et al. Hybrid network with attention mechanism for detection and location of myocardial infarction based on 12-lead electrocardiogram signals[J]. Sensors, 2020, 20(4): 1020.
- [72] Zhao J, Liu H, Ma H, et al. Research of the Approach for the Fetal Heart Sound Signal's Extracting Based on Coif5 Wavelet Transform[J]. Chinese Journal of Biomedical Engineering, 2006, 25(5): 538.
- [73] Chen T H, Han L Q, Xing S X, et al. Research of denoising method of heart sound signals based on wavelet transform[J]. Shinese Medical Equipment Journal, 2010, 27(12): 401-5.
- [74] Cheng X, Zhang Z. Denoising method of heart sound signals based on

- p>self-construct heart sound wavelet[J]. Aip Advances, 2014, 4(8).
- [75]He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 770-778.
- [76]Howard A G, Zhu M, Chen B, et al. Mobilenets: Efficient convolutional neural networks for mobile vision applications[J]. arXiv preprint arXiv:1704.04861, 2017.
- [77]Huang G, Liu Z, Van Der Maaten L, et al. Densely connected convolutional networks[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 4700-4708.
- [78]Learning Cardiac Auscultation: From Essentials to Expert Clinical Interpretation[M]. Springer, 2015.
- [79]Khade S, Subhedar A, Choudhary K, et al. A system to detect heart failure using deep learning techniques[J]. Int. Res. J. Eng. Technol.(IRJET), 2019, 6(6): 384-387.
- [80]Rao S, Li Y, Ramakrishnan R, et al. An explainable transformer-based deep learning model for the prediction of incident heart failure[J]. iee journal of biomedical and health informatics, 2022, 26(7): 3362-3372.
- [81]Acharya U R, Fujita H, Oh S L, et al. Deep convolutional neural network for the automated diagnosis of congestive heart failure using ECG signals[J]. Applied Intelligence, 2019, 49: 16-27.
- [82]Matsumoto T, Kodera S, Shinohara H, et al. Diagnosing heart failure from chest X-ray images using deep learning[J]. International Heart Journal, 2020, 61(4): 781-786.
- [83]Wang X, Peng Y, Lu L, et al. Chestx-ray8: Hospital-scale chest x-ray database and benchmarks on weakly-supervised classification and localization of common thorax diseases[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 2097-2106.
- [84]Zeng Y, Shudong X. New auscultation: can we detect heart failure by auscultation[J]. J. Commun. Med. Pub. Health Rep., 2022, 3: 1.
- [85]Davidsen A H, Andersen S, et al. Diagnostic accuracy of heart auscultation for detecting valve disease: a systematic review[J]. BMJ open, 2023, 13(3): e068121.
- [86]Davidsen A H, Andersen S, Halvorsen P A, et al. Diagnostic accuracy of heart auscultation for detecting valve disease: a systematic review[J]. BMJ open, 2023, 13(3): e068121.
- [87]Jane D , Sheila S , Rikki B ,et al.Murmur clinic: Validation of a new model for detecting heart valve disease[J].Heart (British Cardiac Society), 2018:heartjnl-2018-313393.

附录 相关伦理审查证明

研究对象（可多选）：☒健康人 ☒患者 ☐动物

本论文所涉及研究课题均已通过 天津市第四中心医院 伦理委员会审查，批准号/注册号为：No.2022-T050。

相关伦理审查证明已提交至天津大学学位评定第十八分委员会（医学院）备案。

本人签字：仇兆禹

导师签字：李强

日期：2024.05.28

发表论文与参与科研情况说明

发表的学术论文：

[1] Conference on Artificial Intelligence and Healthcare (CAIH, 2021), 2021, 导师第一作者，本人第四作者

[2] 中国生物医学工程学报，2022，导师第一作者，本人第三作者

[3] Biomedical Signal Processing and Control（在投），导师第一作者，本人第二作者

获得的软件著作权：

[1] 软件著作权，2023，导师第一作者，本人第二作者

参与的科研项目：

[1] 第十五届“挑战杯”大学生课外学术科技作品竞赛

在以上科研项目中，本人负责部分算法设计与软件开发工作。

致谢

首先要感谢党和国家对我的多年栽培，让我有机会从陇亩来到全国重点大学深造多年，培养成了一个更开朗、更努力、始终善良的人。在天津大学的本硕七年学习过程中，思想上不断向组织靠拢，行动上始终践行集体价值观。我已经决心投身于服务国家、建设社会的伟大事业，不负党和国家的二十多年的培育恩泽，立志在平凡的岗位上做出不平庸的业绩！

我要感谢我的导师，余辉副教授治学严谨卓越，为人师表高风亮节，待人接物如春雨甘霖。往后余生，我都会谨记导师在做学问、做人、做事三方面给我的教诲。将导师传授给我的“实事求是”的天大品格融入血脉，将“兴学强国”的天大使命植入灵魂。如果读者你是一位正在寻找导师的本科生，请务必不要错过这位学院公认的好老师！

我要感谢李志刚教授和天津市第四中学医院的医师与护士团队与本研究的通力合作。

我要感谢国家自然科学基金、天津市医工结合专项资金对本研究的大力资助。

我要感谢评审专家们的仔细点评与专业意见。

我要感谢实验室的师兄、师姐、侪辈、师弟、师妹的陪伴。

我要感谢室友好兄弟们的陪伴。

我要感谢 17 教学楼保洁阿姨们的辛勤劳动。

我要感谢鹏翔公寓宿管团队不舍昼夜的付出。

最后，感谢我的父亲、母亲、姐姐、姐夫的支持与陪伴。